

PROJETO FINAL APLICADO EM CIÊNCIA DE DADOS

Caracterização dos Terminais Intermodais de Transporte em Lisboa (Desafio 03|25)

Relatório Final

Parceiro: LxDataLab (Câmara Municipal de Lisboa)
Orientador: Prof. Fernando Batista
Data: Maio 2026
Grupo: G15
Elementos: Gonçalo Mealha – 123391
Jingyu Huang – 123432
José Valério – 112255

Resumo

O presente relatório descreve o trabalho desenvolvido pelo Grupo G15 no âmbito do Projeto Final Aplicado em Ciência de Dados, em parceria com o LxDataLab da Câmara Municipal de Lisboa. O objetivo central foi a caracterização dos quatro principais terminais intermodais de Lisboa — Cais do Sodré, Campo Grande, Sete Rios e Oriente — através da integração de múltiplas fontes de dados heterogéneas, cobrindo o período de janeiro de 2023 a junho de 2025.

A abordagem metodológica seguiu o processo CRISP-DM, e a análise assentou em sete conjuntos de dados: dados de rede móvel Vodafone (*proxy* de afluência), referencial geográfico de quadriculas Vodafone, dados de tráfego Waze, observações meteorológicas IPMA, registos de eventos desportivos, horários de transporte público GTFS (8 operadores) e pontos de interesse Overture Maps. A fase de Data Preparation envolveu um processo extenso de normalização, integração e tratamento de *outliers*, culminando num *dataset* analítico unificado de mais de 5 milhões de registos.

Os resultados evidenciam perfis funcionais marcadamente distintos entre os quatro terminais. O Oriente destaca-se como o principal polo de mobilidade, com os fluxos mais elevados e maior sensibilidade à temperatura. O Campo Grande revela forte dependência de mobilidade pendular e académica, com impactos expressivos dos jogos no Estádio José Alvalade. O Cais do Sodré apresenta um perfil singular de lazer e vida noturna, com atividade pronunciada após as 21h às sextas-feiras e fins de semana. O Sete Rios funciona como *hub* de longa distância, com a maior diversidade de rotas e operadores. A análise dos dados Waze revelou limitações estruturais que impediram conclusões robustas sobre congestionamento, sendo o indicador de *delay* o único operacionalmente válido.

Palavras-chave: terminais intermodais, mobilidade urbana, dados de rede móvel, CRISP-DM, Lisboa, transporte público, Vodafone, Waze, GTFS.

Agradecimentos

Os autores agradecem ao Professor Fernando Batista pela orientação ao longo das doze semanas de projeto. Ao longo das sessões, destacou-se pela forma como reconhecia o que estava bem antes de apontar o que precisávamos de melhorar — com frontalidade, mas sempre com o cuidado de não desencorajar. E acima de tudo, pelo entusiasmo genuíno e contagiante com que transmite conhecimento e pela forma genuína como trata os alunos. A capacidade de se mover com igual à-vontade entre os temas tão distintos desenvolvidos pelos vários grupos da sessão, compreendendo rapidamente as especificidades de cada um e oferecendo sempre uma perspetiva pertinente — como se estivesse por dentro do projeto, fazendo as perguntas certas para iluminar o que ainda podia ser melhorado — foi, para nós, uma fonte de inspiração.

E já agora — obrigado uma vez mais por criar um projeto na sua conta premium do Overleaf para nós. Sem isso, este relatório não existia neste formato e nós não teríamos tido a oportunidade de aprender a trabalhar colaborativamente em LaTeX pela primeira vez.

Ao LxDataLab e à Câmara Municipal de Lisboa, pelo desafio proposto. Trabalhar com dados reais sobre a cidade onde estudamos e nos deslocamos diariamente pela rede de transportes que foi objeto de estudo tornou o projeto genuinamente motivador. Por último, obrigado pelo apreço demonstrado e pelas palavras carinhosas na apresentação final.

Por fim, ao ISCTE, por tudo o que representa além das salas de aula — a comida boa do bar e do refeitório, a sala de estudo e a biblioteca que muitas vezes são um refúgio, as atividades e festas académicas, os corredores, as pessoas, a rotina que se instala sem se dar conta e que, quando acaba, faz falta.

Índice

1	Introdução	1
2	Business Understanding	2
2.1	A Definição de Terminal Intermodal	2
2.2	O Contexto em Lisboa	2
2.3	Relevância do Estudo	2
2.4	Objetivos do Estudo	2
3	Data Understanding	4
3.1	Fontes de Dados	4
3.2	Volume e Período dos Dados	4
3.3	Conjunto 1 — Vodafone Grelha	5
3.3.1	Descrição Geral	5
3.3.2	Estrutura dos Ficheiros e Organização	5
3.3.3	Evolução do Esquema ao Longo dos Anos	7
3.3.4	Principais Problemas nos Dados	7
3.4	Conjunto 2 — Vodafone Quadrículas (Referencial Geográfico)	8
3.4.1	Descrição Geral	8
3.4.2	Estrutura do Ficheiro	9
3.4.3	Mapeamento dos Terminais Intermodais	9
3.5	Conjunto 3 — Waze Jams (Dados de Tráfego)	14
3.5.1	Descrição Geral	14
3.5.2	Estrutura dos Ficheiros	14
3.5.3	Dicionário de Dados	14
3.5.4	Principais problemas nos dados	15
3.6	Conjunto 4 — IPMA (Dados Meteorológicos)	15
3.6.1	Descrição Geral	15
3.6.2	Estações Meteorológicas	16
3.6.3	Estrutura dos Ficheiros	16
3.6.4	Dicionário de Dados	16
3.6.5	Principais Problemas nos Dados	17
3.7	Conjunto 5 — Eventos desportivos (jogos de futebol)	18
3.7.1	Descrição Geral	18
3.7.2	Relevância para a Análise	18
3.8	Conjunto 6 — GTFS (Dados de Transporte Público)	18
3.8.1	Descrição Geral	18
3.8.2	Operadores e Fontes dos Feeds	18
3.8.3	Principais Considerações	19
3.8.4	Estrutura dos Ficheiros	20
3.8.5	Conceitos Fundamentais	20
3.8.6	Metodologia de Associação Geoespacial	21
3.9	Conjunto 7 — Overture Maps (Pontos de Interesse)	21
3.9.1	Descrição Geral	21
3.9.2	Metodologia de Recolha e Tratamento	21
3.9.3	Categorias de POI	22
4	Data Preparation	24
4.1	IPMA	24
4.1.1	Normalização das Variáveis Temporais e de Identificação da Estação	24
4.1.2	Duplicados	24
4.1.3	Agregação dos Dados Meteorológicos	24
4.1.4	Imputação dos períodos omissos	25

4.1.5	Feature Engineering	25
4.1.6	Ajuste da Granularidade Temporal dos Dados Meteorológicos	25
4.2	Eventos Desportivos (Jogos de Futebol)	26
4.2.1	Normalização dos Dados	26
4.2.2	Transformação das Variáveis Temporais	26
4.2.3	Construção de Variáveis Temporais	26
4.3	Vodafone Grelha	26
4.3.1	Filtragem Espacial	26
4.3.2	Normalização das Variáveis	27
4.3.3	Ajuste do Fuso Horário e Conversão para Hora Local	27
4.3.4	Criação de Variáveis Temporais e Estruturais	27
4.3.5	Feature Engineering	27
4.3.6	Integração dos Dados Eventos Desportivos	28
4.3.7	Análise e Tratamento de Outliers da Variável C1	29
4.3.8	Estratégia de Tratamento Adotada	29
4.4	Waze	29
4.4.1	Filtragem das Ocorrências do Waze	29
4.4.2	Ajuste do Fuso Horário e Conversão para Hora Local	30
4.4.3	Conversão e Tratamento da Variável SPEED	30
4.5	GTFS	30
4.6	Integração dos Datasets	30
4.7	Tratamento de Períodos sem Dados	32
5	Modeling — Análises dos Padrões Temporais, Fatores Externos, Oferta dos Operadores dos Terminais e o seu Contexto Urbano	33
5.1	Dimensões Temporais	33
5.2	Eventos Desportivos	41
5.3	Condições Meteorológicas	46
5.4	Congestionamento Rodoviário (Waze)	51
5.5	Oferta de Transporte Público e Alinhamento com a Afluência (GTFS)	61
5.6	Contexto Urbano dos Terminais (Overture Maps)	68
5.7	Padrões de Mobilidade de Visitantes Internacionais (Roaming)	73
6	Evaluation — Conclusões	75
6.1	Síntese Comparativa dos Terminais	75
6.2	Principais Conclusões	76
6.3	Limitações do Estudo	76
7	Deployment — Comunicação de Resultados	78
7.1	Relatório	78
7.2	Código	78
7.3	Dashboard Power BI	78
	Bibliografia	79
	Anexo I - Inspeção dos Ficheiros CSV	80
a)	Metodologia de Inspeção	80
b)	Resultados Globais	80
c)	Schemas Confirmados por Fonte	80
d)	Ficheiros com Formato Anómalo	82
e)	Anomalia de Linhas Vazias em Ficheiros Waze (Terminações CRLF)	82
	Anexo II - Web Scraping aos Dados da Rede Expressos	83
a)	Contexto e Motivação	83
b)	Descoberta da API Interna	83

c)	Desafios Técnicos e Soluções Adoptadas	85
d)	Estratégia e Volume de Recolha	87
e)	Estrutura dos Dados Recolhidos	88
f)	Dependências e Requisitos de Execução	89
g)	Limitações e Considerações Metodológicas	89
Anexo III - Análise e Tratamento de Outliers da Variável C1		91
h)	Análise e Tratamento de Outliers da Variável C1	91
i)	Validação de Legitimidade dos Fliers C1	96

1 Introdução

Este projeto, desenvolvido no âmbito da unidade curricular *Projeto Final Aplicado em Ciência de Dados*, tem como objetivo aplicar todos os conceitos lecionados ao longo da licenciatura.

O trabalho foi articulado com a Câmara Municipal de Lisboa (LxDataLab) cujo desafio consiste em caracterizar os terminais intermodais de transporte em Lisboa com base em fatores temporais, meteorológicos e de tráfego rodoviário.

Num contexto urbano marcado por fluxos elevados de mobilidade diária, os terminais intermodais assumem um papel fundamental na articulação entre diferentes modos de transporte. Assim, a sua caracterização e análise permitem compreender padrões de utilização, dinâmicas temporais e espaciais, bem como identificar possíveis oportunidades de otimização ao nível do planeamento e da gestão da rede da mobilidade urbana.

O presente trabalho centra-se nas principais interfaces intermodais de Lisboa e procura identificar evidências empíricas que apoiem a tomada de decisão por parte das entidades responsáveis pela mobilidade urbana.

A abordagem metodológica adotada neste projeto baseia-se no CRISP-DM (*Cross Industry Standard Process for Data Mining*), conforme ilustrada na figura abaixo.




Figura 1: CRISP-DM (Cross Industry Standard Process for Data Mining)

Esta metodologia organiza o desenvolvimento do projeto de Ciência de Dados em seis etapas estruturadas: *Business Understanding*, *Data Understanding*, *Data Preparation*, *Modeling*, *Evaluation* e *Deployment*. Estas etapas não são estritamente lineares, permitindo iterações sempre que necessário, em função dos resultados obtidos em cada fase.

2 Business Understanding

2.1 A Definição de Terminal Intermodal

Um terminal de transportes corresponde a uma infraestrutura física destinada ao início, fim ou paragem de serviços de transporte, assegurando a organização operacional das chegadas e partidas de veículos e passageiros. Dependendo da sua escala e função, podem assumir características locais, regionais ou metropolitanas.

Outro conceito que por vezes vem associado a um terminal, é a intermodalidade, que segundo o glossário do IMTT é a “característica de um sistema de transportes que proporciona complementaridade e soluções em cadeia que permitem a conexão entre diferentes modos e meios de transporte tendo em vista satisfazer determinada deslocação/viagem entre uma origem e um destino pré-definidos.” (Guião Orientador - Acessibilidades, mobilidade e transportes nos planos municipais de ordenamento do território, 2011). Desta forma, para que o conceito de intermodalidade exista, são necessários pelo menos dois meios diferentes de transporte de maneira integrada, o que supõe pelo menos uma troca de modos ou meios diferentes.

Deste modo, um terminal intermodal é um espaço físico que integra diferentes modos de transporte, possibilitando transferências de passageiros entre esses diferentes modos numa só viagem. Para além da função operacional de terminal, estas estruturas desempenham um papel estratégico na organização da mobilidade urbana, funcionando como polos de articulação.

2.2 O Contexto em Lisboa

Numa cidade com a dimensão de Lisboa, os terminais intermodais acabam por ter um papel preponderante, movimentando centenas de milhares de pessoas diariamente. Dados recentes indicam que o sistema de transportes públicos na Área Metropolitana de Lisboa registou níveis de procura sem precedentes, com o Metropolitano de Lisboa a transportar mais de 126 milhões de passageiros nos primeiros nove meses de 2024 e a Carris Metropolitana a alcançar um total de 194 milhões de passageiros ao longo de 2025, com dias de semana a superar os 760 mil passageiros num único dia útil, ilustrando a intensidade da mobilidade na região.¹

No município, existem 20 interfaces que albergam mais do que um meio de transporte, destacando-se as seguintes: Cais do Sodré (comboio, metropolitano, autocarro e barco), Sete Rios (comboio, metropolitano, autocarro e autocarro de longo curso), Oriente (comboio, metropolitano, autocarro e autocarro de longo curso) e Campo Grande (metropolitano, autocarro e autocarro interurbano). Estas 4 serão o foco deste estudo.

2.3 Relevância do Estudo

A caracterização dos principais terminais intermodais permite compreender dinâmicas espaciais e temporais da procura pelos serviços, identificar potenciais estrangulamentos operacionais e apoiar decisões de planeamento mais informadas.

Essa análise envolve diversos *stakeholders* institucionais e operacionais, cujas decisões podem beneficiar diretamente dos resultados obtidos. Destaca-se a Câmara Municipal de Lisboa, nomeadamente a Direção Municipal de Mobilidade (DMM) que é responsável pelos transportes e tráfego da cidade. Ao nível operacional, assumem particular relevância operadores como a Carris, o Metropolitano de Lisboa e a CP – Comboios de Portugal, cuja oferta pode ser ajustada com base nos resultados produzidos.

2.4 Objetivos do Estudo

O presente estudo pretende caracterizar os principais terminais intermodais de Lisboa, analisando a influência das horas de ponta, do tipo de dia, do calendário escolar, das condições meteorológicas e dos níveis de congestionamento rodoviário. A compreensão destas dinâmicas permitirá apoiar decisões estratégicas no domínio da mobilidade urbana, contribuindo para um sistema de transportes mais eficiente.

De forma mais específica, o estudo procura atingir os seguintes objetivos:

¹<https://www.metrolisboa.pt/institucional/2024/11/30/metropolitano-de-lisboa-atinge-numero-recorde-de-transporte-de-passageiros/>

Quantificar e caracterizar os fluxos de mobilidade nas interfaces: identificar o volume de entradas, saídas e pessoas presentes nas áreas envolventes de cada terminal, permitindo descrever a intensidade e a dinâmica dos fluxos.

Analisar a variabilidade temporal dos fluxos: avaliar as flutuações de mobilidade ao longo do dia, com particular foco nas horas de ponta, e comparar os padrões observados entre dias úteis e fins de semana.

Avaliar o impacto do calendário escolar: analisar as diferenças nos fluxos de mobilidade entre períodos letivos e períodos de férias escolares.

Analisar a influência das condições meteorológicas: avaliar a sensibilidade dos fluxos de passageiros a variáveis como temperatura, precipitação e vento.

Relacionar mobilidade e congestionamento rodoviário: analisar os níveis de congestionamento e atrasos (delays) nas vias em torno das interfaces nos diferentes contextos temporais.

Avaliar o impacto de eventos desportivos: analisar de que forma os jogos de futebol influenciam os fluxos de passageiros nas interfaces próximas dos estádios.

Analisar a relação entre oferta de transporte e procura: comparar os fluxos observados com a oferta programada de transporte público (dados GTFS), avaliando o grau de alinhamento entre oferta e procura.

Caracterizar o contexto urbano das interfaces: analisar a distribuição de pontos de interesse na área envolvente de cada terminal, avaliando de que forma a estrutura urbana influencia os padrões de mobilidade.

Comparar o comportamento das diferentes interfaces intermodais: identificar diferenças entre os terminais analisados quanto à intensidade dos fluxos, padrões temporais e sensibilidade a fatores externos.

3 Data Understanding

3.1 Fontes de Dados

Os dados foram disponibilizados pelo LxDataLab e englobam o período de Janeiro de 2023 a Junho de 2025. Estão organizados em quatro conjuntos complementares, descritos na ficha de projeto oficial (***Ficha202503 Caracterização dos terminais intermodais.xlsx***):

#	Conjunto	Descrição resumida
1	Vodafone Grelha	Dados de rede móvel por célula de grelha (200m × 200m) — contagens de terminais, entradas, saídas e indicadores de tráfego de dados
2	Vodafone Quadrículas	Referencial geográfico das 3743 células de grelha que cobrem Lisboa — geometria poligonal e metadados de localização
3	Waze Jams	Ocorrências de congestionamento viário na cidade de Lisboa — localização da ocorrência, nível de gravidade do congestionamento, duração de delays
4	IPMA	Observações meteorológicas horárias de 3 estações em Lisboa — temperatura, precipitação, vento, humidade, pressão e radiação solar

Observação:

Após alguma pesquisa, percebemos que o prefixo **PGIL** presente nos nomes de várias pastas e ficheiros (ex: *PGIL_WAZE_JAMS_*, *PGIL_IPMA_METEO_OBS_*) corresponde à Plataforma de Gestão Inteligente de Lisboa, desenvolvida pela empresa japonesa NEC e adotada pela Câmara Municipal de Lisboa no âmbito da estratégia Lisboa Cidade Inteligente. É através desta plataforma que os dados são recolhidos, agregados e disponibilizados pelo LxDataLab.²

3.2 Volume e Período dos Dados




Figura 2: Número de ficheiros por conjunto de dados

O conjunto de dados disponibilizado para este projeto é de dimensão considerável, totalizando 156 GB em 157 ficheiros CSV. Trata-se de um volume expressivo, exigindo uma abordagem cuidadosa na exploração e processamento dos dados, nomeadamente em termos de eficiência computacional. Em termos de distribuição

²Lisboa Inteligente. LISBOA ABERTA. Published 2019. Accessed March 6, 2026. <https://lisboaaberta.cm-lisboa.pt/index.php/pt/lisboa-inteligente>

Smart Cities. PGIL: Agregar dados e informação para servir a cidade de Lisboa. Smart Cities. Published January 26, 2022. Accessed March 6, 2026. <https://smart-cities.pt/smn/nec-plataforma-lisboa-2601/>

Intelligent Management Platform makes the city of Lisbon smarter. NEC. Published 2019. Accessed March 6, 2026. <https://www.nec.com/en/global/onlinetv/en/lisbon.html>

por fonte, Vodafone Grelha é o *dataset* de maior peso, tanto em número de ficheiros como em volume total de registos (ver Figuras 2 e 3), com mais de 900 milhões de linhas acumuladas.

Os dados Waze Jams representam também um contributo significativo. Por sua vez, os dados IPMA, têm uma dimensão mais contida.




Figura 3: Número total de registos por conjunto de dados

O período de cobertura global estende-se de Janeiro de 2023 a Junho de 2025, permitindo análises de tendência ao longo de dois anos e meio. Esta janela temporal abrange diferentes épocas sazonais e vários eventos relevantes para a mobilidade urbana em Lisboa.

Conjunto	Período	Granularidade
Vodafone Grelha	Jan 2023 – Jun 2025	5 minutos
Vodafone Quadriculas	Estático (referencial)	N/A (estático)
Waze Jams	Jan 2023 – Jun 2025	Evento contínuo
IPMA	Jan 2023 – Jun 2025	Horária

Nos próximos capítulos vamos então proceder à descrição e caracterização dos dados presentes em cada um dos conjuntos, assim como anotar observações que vão sendo realizadas à medida que esta fase de compreensão de dados se desenvolve.

3.3 Conjunto 1 — Vodafone Grelha

3.3.1 Descrição Geral

O Conjunto 1 contém dados de rede móvel da Vodafone Portugal relativos à presença e movimentação de terminais (dispositivos móveis neste caso) nas células de grelha que cobrem a cidade de Lisboa. Cada célula tem dimensão de aproximadamente 200m × 200m e é identificada por um `Grid_ID` numérico.

Os dados permitem inferir padrões de afluência e mobilidade nos terminais intermodais a partir da contagem de entradas (C5) e saídas (C6) de terminais em cada célula ao longo do tempo.

3.3.2 Estrutura dos Ficheiros e Organização

Os ficheiros encontram-se organizados na pasta `VODAFONE GRELHA/` com a seguinte hierarquia:

Pasta/Ficheiros	Período	Estrutura
Vodafone grelha 2023/MM_2023/	Jan–Dez 2023	12 subpastas (uma por mês) contendo ficheiros CSV, divididos por intervalos de Grid_ID (ex: _1_1000.csv, _1000_2000.csv, etc)
Vodafone grelha 2024/MM_2024/	Jan–Ago 2024	10 subpastas mensais com ficheiros CSV por mês, divididos por intervalos de Grid_ID mais granulares (ex: _1_500.csv, _501_1000.csv)
Vodafone grelha 2024/11_2024.csv Vodafone grelha 2024/12_2024.csv	Nov–Dez 2024	Ficheiros CSV únicos na raiz da pasta 2024 (sem subpasta).
Vodafone grelha_2025/MM_2025.csv	Jan–Jun 2025	Ficheiros CSV únicos mensais.

Dicionário de Dados

A tabela seguinte apresenta todos os campos documentados e inspecionados pelo grupo, com indicação da sua disponibilidade em cada período.

Campo	Descrição	2023	2024 Jan-Ago	2024 Out-Dez/2025	Tipo
Grid_ID / grid_id	Identificador numérico da célula de grelha (1 a 3743)	Sim	Sim	Sim	Numérico
Datetime / date	Timestamp de início do intervalo de observação	Sim	Sim	Sim	Timestamp
C1	Número total de terminais distintos observados na célula durante o intervalo	Sim	Sim	Sim	Numérico
C2	Número de terminais em roaming na célula	Não	Sim	Sim	Numérico
C3	Número de terminais distintos que permanecem na quadrícula	Sim	Sim	Sim	Numérico
C4	Número de terminais em roaming presentes no final do intervalo	Não	Sim	Sim	Numérico
C5	Número de entradas de terminais distintos na célula durante o intervalo	Sim	Sim	Sim	Numérico
C6	Número de saídas de terminais distintos da célula durante o intervalo	Sim	Sim	Sim	Numérico
C7	Número de entradas de terminais em roaming	Não	Sim	Não	Numérico
C8	N.º de saídas de terminais distintos, em roaming, na quadrícula. — campo ausente em todos os ficheiros	N/A	N/A	N/A	—
C9	Número de terminais com ligação de dados ativa durante o intervalo	Sim	Sim	Não	Numérico
C10	Número de terminais em roaming com ligação de dados ativa	Não	Sim	Não	Numérico

Campo	Descrição	2023	2024 Jan-Ago	2024 Out- Dez/2025	Tipo
C11	Número de chamadas de voz com origem na célula	Não	Sim	Não	Numérico
D1	Top 10 países de origem de terminais em roaming	Não	Sim	Não	String
E1–E10	Série de indicadores adicionais (E1 chamadas, E2 débito down, etc.)	Sim	Sim	Não	Numérico
year	Ano do registo (campo auxiliar)	Não	Não	Sim	Numérico

Observações:

Anomalia pontual (Fevereiro 2024): O ficheiro *PgilVodafone_202402_2001_2500.csv* apresenta 10 colunas em vez das 23 esperadas. Todos os restantes ficheiros de Fevereiro têm 23 colunas. Esta anomalia isolada deverá ser tomada em consideração na fase de Data Preparation.

Anomalia (Setembro 2024): Setembro 2024 não dispõe de ficheiros no formato habitual de 23 colunas e repartidas em grids. O único ficheiro disponível é *PgilVodafoneA_202409_1_3743.csv*, com 8 colunas e capitalização mista (grid_id e date em minúsculas, C1–C6 em maiúsculas). Esta lacuna de cobertura deverá também ser considerada na fase de Data Preparation.

3.3.3 Evolução do Esquema ao Longo dos Anos

O esquema dos ficheiros Vodafone Grelha sofreu alterações significativas entre períodos, constituindo um dos principais desafios de preparação de dados deste projeto. Foram identificados três esquemas distintos:

Período	N. colunas	Colunas presentes	Observações
2023 (Jan–Dez)	10	Grid_ID, Datetime, C1, C3, C5, C6, C9, E7, E8, E9	Nomes de colunas em maiúsculas (Grid_ID, Datetime). Timestamp com Z (ex: 2023-01-01T00:00:00.000Z). Esquema reduzido — sem C2, C4, C7, C10, C11, D1, E1–E6, E10
2024 Jan–Ago	23	Grid_ID, Datetime, C1, C2, C3, C4, C5, C6, C7, C9, C10, C11, D1, E1–E10	Esquema mais completo. Mantém nomes em maiúsculas. D1 é campo de texto com valores NaN frequentes. Timestamp com Z
2024 Out–Dez e 2025	9	grid_id, date, c1, c2, c3, c4, c5, c6, year	ESQUEMA DIFERENTE: nomes em minúsculas, campo date (sem T e Z), coluna year adicional. Sem C7–C11, sem D1, sem série E. Formato timestamp: 2024-11-01 00:00:00.000

Ver Anexo I para detalhe sobre os schemas identificados por período.

3.3.4 Principais Problemas nos Dados

A análise exploratória dos dados de mobilidade provenientes da Vodafone revelou a existência de algumas limitações relevantes, que devem ser consideradas na interpretação dos resultados.

Diferenças na nomenclatura das variáveis Primeiramente, tal como referido na secção anterior, o esquema dos ficheiros sofreu alterações ao longo dos dois anos e meio abrangidos pelo período de análise, o que resultou em inconsistências na estrutura dos dados. Em particular, verificam-se atributos conceptualmente

idênticos definidos de forma distinta (por exemplo, *Datetime* e *date*), bem como variações na nomenclatura das variáveis, cujos nomes surgem alternadamente em maiúsculas e minúsculas.

Lacunas temporais Verifica-se também a existência de lacunas temporais significativas, com ausência total de registos em determinados períodos. Esta situação é particularmente evidente nos meses de agosto e setembro de 2024, nos quais se identificam vários dias consecutivos sem qualquer informação disponível. Esta irregularidade é visível na evolução mensal do número de registos (Figura 4), onde se observa uma quebra acentuada nesses meses. Estas falhas são indicativas de possíveis problemas na recolha ou disponibilização dos dados, não devendo ser interpretadas como ausência real de mobilidade.




Figura 4: Número de registos por mês (Vodafone Grelha)

Inconsistências nas contagens de dispositivos Em terceiro lugar, observa-se que, na grande maioria dos casos, os dados não respeitam a condição de consistência dos fluxos, segundo a qual o número de dispositivos presentes num determinado período ($C1$) deveria ser igual ou aproximadamente igual ao número de dispositivos presentes no período anterior acrescido das entradas ($C5$) e subtraídas as saídas ($C6$):

$$C1(t) = C1(t - 1) + C5(t) - C6(t)$$

Na prática, verifica-se que esta relação raramente é satisfeita, o que sugere a presença de ruído, erros de medição ou limitações inerentes ao processo de estimação dos fluxos a partir de dados de telecomunicações.

Erros de medição Por fim, foram identificados valores claramente anómalos nos contadores, incompatíveis com o contexto temporal e espacial. Um exemplo ilustrativo corresponde à deteção de 8185 dispositivos às 04:55 da manhã na zona do Cais do Sodré, um valor manifestamente irrealista tendo em conta o período horário em causa. Situações deste tipo indicam a existência de erros de medição ou de processamento dos dados, tendo sido tratadas como observações inválidas no âmbito do presente estudo.

3.4 Conjunto 2 — Vodafone Quadrículas (Referencial Geográfico)

3.4.1 Descrição Geral

O ficheiro VODAFONE_QUADRICULAS.xlsx constitui o referencial geográfico das células de grelha. Contém informação sobre as **3743** células que cobrem o território de Lisboa, incluindo a sua localização, área administrativa (freguesia) e geometria poligonal completa da grelha (dados em GeoJSON).

Este ficheiro é essencial para cruzar os dados de rede móvel (Conjunto 1) com a localização geográfica real, permitindo visualizações de análise espacial. O ficheiro é estático — não tem dimensão temporal.

3.4.2 Estrutura do Ficheiro

O ficheiro XLSX contem duas folhas (sheets): ‘**em bruto**’ e ‘**resumo**’. Ambas contêm **3743** linhas.

Sheet: em bruto (14 colunas) Versão completa com todos os campos, incluindo a geometria poligonal de cada célula. Esta sheet é necessária para análise espacial:

Campo	Tipo	Descrição
grelha_id	Numérico	Identificador da célula — chave primária e campo de ligação
dicofre	String	Código DICOFRE de 6 dígitos da unidade administrativa (freguesia) em questão. Composto por 2 dígitos em cada uma das seguintes: - DI (Distrito) - CO (Concelho) - FRE (Freguesia)
entity_id	String	Identificador único da célula no sistema da PGIL
entity_type	String	Tipo de entidade registada na plataforma PGIL
freguesia	String	Nome da freguesia principal da célula
freguesias	String	Lista de freguesias abrangidas pela célula (pode intersectar mais do que uma)
grelha_x	Numérico	Coordenada X da célula na grelha interna da Vodafone
grelha_y	Numérico	Coordenada Y da célula na grelha interna da Vodafone
latitude	Numérico	Latitude do centroide da célula
longitude	Numérico	Longitude do centroide da célula
nome	String	Topónimo / nome de rua ou zona associada à célula (pode ser nulo)
objectid	Numérico	Identificador interno que é igual ao grelha_id
position	String (GeoJSON)	Geometria do polígono da célula em formato GeoJSON (Polygon com coordenadas dos 4 vértices do quadrado 200m x 200m)
wkt	String (WKT)	Geometria do polígono em formato WKT (Well-Known Text)

Sheet: resumo (4 colunas) Versão simplificada dos dados em bruto, com os campos essenciais para filtrar e identificar células por localização administrativa ou coordenadas do centróide:

Campo	Tipo	Descrição
grelha_id	Numérico	Identificador numérico da célula (1 a 3743) — chave de ligação com o Conjunto 1
freguesia	String	Nome da freguesia de Lisboa a que a célula pertence
latitude	Numérico	Latitude do centroide da célula (coordenadas geográficas)
longitude	Numérico	Longitude do centroide da célula (coordenadas geográficas)

3.4.3 Mapeamento dos Terminais Intermodais

Um facto que nos ajudará a lidar com este enorme volume de dados é que – dos **3743** Grid_IDs que cobrem Lisboa, apenas um subconjunto corresponde aos quatro terminais intermodais em estudo. Isto facilitará de forma tremenda a filtragem e a posterior manipulação dos dados para análises subseqüentes.

Este mapeamento é definido num dos documentos de referência facultados denominado ‘***Gre-lhas_Interfaces.pdf***’. Segue abaixo o referido mapeamento nesse documento:




Figura 6: Células do Terminal Intermodal de Cais do Sodré

Sete Rios

No Terminal Intermodal de Sete Rios, a análise espacial evidenciou que a célula **1781** incidia sobre o parque de estacionamento reservado às operações de autocarros, um espaço de uso maioritariamente logístico e com presença de passageiros muito reduzida. Após deliberação em grupo, foi decidido substituí-la pela célula **1841**, que corresponde ao edifício terminal propriamente dito — o espaço onde os passageiros adquirem bilhetes, aguardam, embarcam e desembarcam dos serviços de longo curso — englobando adicionalmente uma paragem de autocarro urbano na via pública adjacente.

Importa ainda assinalar que a célula **1839**, embora não seja contígua às restantes e se encontre, na sua maioria, na área do Jardim Zoológico, foi mantida no mapeamento por cobrir a zona de acesso à estação de metro e uma paragem de autocarro urbano. O terminal ficou assim composto pelas células 1719, 1720, 1780, 1839 e 1841.



Figura 7: Células do Terminal Intermodal de Sete Rios

Campo Grande

No Terminal Intermodal de Campo Grande, a análise identificou que a célula **2677** incidia sobre o Estádio de Alvalade, uma infraestrutura desportiva sem qualquer interface de transporte público na sua área de cobertura. Esta célula revelava-se problemática por dois motivos: em condições normais, a sua contribuição para a caracterização do tráfego de passageiros seria muito perto de nula; e em dias de jogo do Sporting Clube de Portugal em casa, o afluxo massivo de adeptos faria disparar artificialmente o número de dispositivos registados, adulterando de forma significativa os padrões de mobilidade do terminal. Após deliberação em grupo, foi decidido substituí-la pela célula **2616**, que abrange um grande conjunto de paragens de autocarro urbano, bem como parte das áreas de acesso à estação de Metro do Campo Grande. O terminal ficou assim composto pelas células 2615, 2616, 2678 e 2679.



Figura 8: Células do Terminal Intermodal de Campo Grande

Oriente

No Terminal Intermodal do Oriente, além do problema já identificado (células 3951 e 3952 excedem o identificador máximo existente de 3743), a análise visual confirmou ainda que a célula **3070** incidia sobre uma zona urbana de carácter residencial e comercial, sem qualquer interface de transporte público identificável na sua área de cobertura. Na sequência de deliberação conjunta, foi decidido substituí-la pela célula **2952**, que abrange parte da área da estação ferroviária do Oriente, garantindo uma maior fidelidade à localização real do terminal. O terminal ficou assim composto pelas células 3011, 3012, 3071 e 2952.

3.5 Conjunto 3 — Waze Jams (Dados de Tráfego)

3.5.1 Descrição Geral

O Conjunto 3 contém dados de congestionamento viário fornecidos pela plataforma Waze. Cada registo representa um evento de tráfego identificado pelo algoritmo do Waze, com informação sobre a sua localização, extensão, velocidade, duração de atraso e nível de gravidade do congestionamento (“jam”).

Estes dados permitem correlacionar os padrões de afluência nos terminais intermodais com as condições do tráfego nas vias de acesso envolventes, constituindo uma variável contextual relevante para a análise dos picos horários.

3.5.2 Estrutura dos Ficheiros

Os ficheiros encontram-se organizados na pasta WAZE_JAMS/ com naming inconsistente entre anos:

Pasta	Padrão de nomes	Período	N. ficheiros
PGIL_WAZE_JAMS_2023/	PGIL_WAZE_JAMS_MM_2023.csv	Jan–Dez 2023	12
PGIL_WAZE_JAMS_2024/	waze_MM_2024.csv	Jan–Dez 2024	12
PGIL_WAZE_JAMS_2025/	waze_2025_MM.csv	Jan–Jun 2025	7

Observações:

Existem dois ficheiros para Janeiro de 2025 — *waze_2025_01.csv* e *waze_2025_01_2.csv*. Após uma breve investigação confirmou-se que simplesmente se tratava da sequência de registos para esse mês.

3.5.3 Dicionário de Dados

O esquema é consistente em todos os ficheiros (2023, 2024 e 2025) — 8 campos:

Campo	Tipo	Descrição
delay	Numérico	Atraso estimado em segundos face ao tempo de circulação livre. Valor especial: -1 indica via completamente bloqueada (corresponde a level=5)
entity_id	String	Identificador único registado na PGIL
entity_ts	Timestamp	Timestamp do registo do evento na PGIL (que deverá ser o Timestamp da ocorrência registada na plataforma Waze, uma vez que se trata do único Timestamp disponível neste conjunto de dados)
length	Numérico	Extensão do congestionamento em metros
level	Numérico (0–5)	Nível de gravidade do congestionamento — escala de 0 (fluxo livre) a 5 (bloqueado). Ver tabela de níveis abaixo
position	String (GeoJSON)	Localização geográfica do congestionamento em formato GeoJSON (GeometryCollection com MultiLineString) — representa o traçado da via afetada
speed	Numérico (m/s)	Velocidade média de circulação na via em metros por segundo
street	String (nullable)	Nome da via pública afetada. Pode ser nulo quando o Waze não consegue identificar o nome da rua

Escala de Níveis de Congestionamento (field: level)

Level	Classificação	Interpretação
0	livre de tráfego (100-80% de velocidade de fluxo livre)	Circulação sem quaisquer restrições
1	80-61% de velocidade de fluxo livre de tráfego	Tráfego em movimento
2	60 a 41%	Redução considerável da velocidade
3	40 a 21%	Congestão moderada com paragens frequentes
4	20 a 1%	Tráfego com paragens frequentes e avanço lento
5	Via Bloqueada	Via completamente bloqueada por motivo que não foi esclarecido ou facultado na descrição dos dados mas que assumimos que se deva a acidentes ou outras situações extremas e raras provenientes das horas de ponta. O campo delay assume o valor -1 nesta situação

3.5.4 Principais problemas nos dados

À semelhança do conjunto da Vodafone Grelha, verifica-se também a existência de lacunas temporais significativas, com ausência de registos em determinados períodos. Esta irregularidade é visível na evolução mensal do número de registos (Figura 10), onde se observa uma quebra acentuada no mês de outubro de 2024. Estas falhas são indicativas de possíveis problemas na recolha ou disponibilização dos dados, não devendo ser interpretadas como ausência real de mobilidade.




Figura 10: Número de registos por mês (Waze)

3.6 Conjunto 4 — IPMA (Dados Meteorológicos)

3.6.1 Descrição Geral

O Conjunto 4 contém observações meteorológicas horárias de estações do IPMA (Instituto Português do Mar e da Atmosfera) localizadas em Lisboa. Estes dados são fundamentais para correlacionar os padrões de afluência nos terminais intermodais com as condições climáticas, em particular a precipitação.

3.6.2 Estações Meteorológicas

Estão disponíveis registos de três estações meteorológicas localizadas em Lisboa:

Código (estacion)	Nome da Estação	Localização	Elevação
01200535	Lisboa Geofísico	Lat. 38°43'9"N / Lon. 9°8 Junto ao Observatório Astronómico da Faculdade de Ciências	77 m
01200579	Lisboa Gago Coutinho	Lat. 38°46'N / Lon. 09°08W Aeroporto Humberto Delgado	104 m
01210762	Lisboa Tapada da Ajuda	Lat. 38°42'36"N / Lon. 9°10'48"W	62 m

3.6.3 Estrutura dos Ficheiros

Ficheiro	Período	Observação
IPMA 2023/PGIL_IPMA_METEO_OBS_2023_SEM1.csv	Jan–Jun 2023	Ficheiro normal. Separador vírgula, 11 colunas
IPMA 2023/PGIL_IPMA_METEO_OBS_2023_SEM2.csv	Jul–Dez 2023	Ficheiro normal. Esquema idêntico ao SEM1
IPMA 2024/PGIL_IPMA_METRO_OBS_1Sem2024.csv	Jan–Jun 2024	Atenção: nome do ficheiro contem METRO em vez de METEO (typo). Wildcards *METEO* falham para 2024
IPMA 2024/PGIL_IPMA_METRO_OBS_2Sem2024.csv	Jul–Dez 2024	Mesmo typo no nome do ficheiro (METRO). Esquema idêntico
IPMA_2025/PGIL_IPMA_METEO_OBS_1Sem2025.csv	Jan–Jun 2025	Formato CSV anómalo — linhas inteiras encapsuladas em aspas duplas com campos internos escapados (\"campo\"). Requer processamento especial antes da ingestão (ver secção d) do Anexo I)

3.6.4 Dicionário de Dados

O esquema é consistente em todos os ficheiros (2023 e 2025) — 11 campos. A ordem das colunas varia entre 2023 e 2024, mas os campos são os mesmos:

Campo	Tipo / Unidade	Descrição
entity_id	String	Identificador completo da estação no sistema de dados da PGIL (ex: ipma.01200535)
estacion	String	Código numérico da estação meteorológica (01200535, 01200579 ou 01210762). Corresponde ao id oficial IPMA
humidade	Numérico (%)	Humidade relativa do ar em percentagem. Valor -99 indica dado em falta

Campo	Tipo / Unidade	Descrição
iddireccvento	Numérico (0–9)	Identificador da direção do vento (escala discreta). (0: sem rumo, 1 ou 9: "N", 2: "NE", 3: "E", 4: "SE", 5: "S", 6: "SW", 7: "W", 8: "NW")
intensidadeventokm	Numérico (km/h)	Intensidade (velocidade) do vento em quilómetros por hora. Valor -99 indica dado em falta
precacumulada	Numérico (mm)	Precipitação acumulada em milímetros — variável principal para correlação com afluência. Valor -99 indica dado em falta ou precipitação nula
pressao	Numérico (hPa)	Pressão atmosférica em hectopascas. Valor -99 indica dado em falta
radiacao	Numérico (W/m2)	Radiação solar global em watts por metro quadrado. Valor -99 indica dado em falta
temperatura	Numérico (graus C)	Temperatura do ar em graus Celsius. Valor -99 indica dado em falta
fecha	Timestamp	Timestamp da leitura efectuada pela estação meteorológica (granularidade horária). É este o campo a usar para cruzar os dados dos outros conjuntos e realizar análise temporal.
entity_ts	Timestamp	Timestamp de ingestão do registo na plataforma PGIL. Representa o momento em que o sistema recebeu e guardou a leitura. Em 2024, este campo aparece primeiro no CSV

3.6.5 Principais Problemas nos Dados

A análise exploratória dos dados meteorológicos do IPMA permitiu identificar um conjunto de limitações relevantes que devem ser consideradas na fase de tratamento e preparação dos dados.

Duplicados Em primeiro lugar, foram identificados 2189 casos de potenciais duplicados ao nível da combinação estação–data–hora. Numa primeira instância, estes registos aparentam ser duplicados, uma vez que partilham os mesmos atributos temporais e de localização. No entanto, uma análise mais detalhada das variáveis meteorológicas revelou que uma parte significativa destes casos corresponde, na realidade, a “falsos duplicados”.

Nestes casos, é frequente observar a coexistência de dois registos para o mesmo período em que:

- um dos registos apresenta valores nulos ou iguais a zero em todas as variáveis meteorológicas;
- o outro registo contém valores observados válidos para essas variáveis.

Assim, estes registos não devem ser considerados duplicados no sentido estrito, podendo, pelo contrário, conter informação complementar. Ainda assim, a análise mostrou que nem todos os casos seguem este padrão:

- 1015 grupos contêm pelo menos um registo totalmente nulo ou com valores zero, sugerindo a presença de observações inválidas;
- 1174 grupos não apresentam esse comportamento, correspondendo a duplicados reais, onde coexistem múltiplos registos com os mesmos valores para o mesmo período.

Adicionalmente, verificou-se que nem sempre a primeira observação de cada grupo duplicado corresponde a um registo inválido, o que impede a aplicação de estratégias simples de remoção (como a seleção sistemática da primeira ocorrência), exigindo uma abordagem mais criteriosa no processo de limpeza.

Períodos omissos Por fim, foram identificados 721 períodos horários sem qualquer registo, evidenciando a existência de lacunas temporais no *dataset*. Estas falhas podem comprometer análises de séries temporais e exigem a aplicação de técnicas de imputação para garantir a continuidade dos dados.

3.7 Conjunto 5 — Eventos desportivos (jogos de futebol)

3.7.1 Descrição Geral

Com o objetivo de analisar o impacto de eventos de grande afluência no uso de transportes públicos, foi integrada uma nova fonte de dados relativa a jogos de futebol realizados na cidade de Lisboa.

Foram recolhidas informações sobre a data e hora de cada jogo, abrangendo competições nacionais e europeias, realizado nos principais estádios da cidade: o Estádio da Luz (Sport Lisboa e Benfica) e o Estádio de Alvalade (Sporting Clube de Portugal). O período considerado estende-se desde o início de 2023 até junho de 2025, cobrindo parcialmente a época 2022/2023, a totalidade da época 2023/2024 e parte da época 2024/2025.

Os dados foram obtidos a partir da plataforma FixtureDownload (<https://fixturedownload.com>), que disponibiliza diversas informações sobre jogos de várias modalidades em formato CSV, permitindo uma integração direta com as restantes bases de dados do estudo. As únicas exceções correspondem aos jogos nacionais da segunda metade da época 2022/2023 (início de 2023) e a alguns jogos de competições secundárias (Taça de Portugal e Taça da Liga), para os quais não foi possível obter informação através desta fonte, tendo sido necessário pesquisá-los e preencher a informação manualmente.

3.7.2 Relevância para a Análise

A introdução desta fonte permite incorporar o efeito de eventos de grande dimensão na análise dos fluxos de mobilidade, possibilitando:

- comparar períodos com e sem jogos;
- avaliar variações no volume de entradas e saídas nos terminais;
- identificar padrões específicos associados a eventos desportivos.

Desta forma, é possível ter uma maior compreensão dos fatores que influenciam a dinâmica da mobilidade urbana em Lisboa.

3.8 Conjunto 6 — GTFS (Dados de Transporte Público)

3.8.1 Descrição Geral

Este capítulo documenta uma nova fonte de dados integrada no projeto: os *feeds* GTFS (*General Transit Feed Specification*) dos operadores de transporte público com presença nos quatro terminais intermodais em estudo. O GTFS é um formato aberto e padronizado para a descrição de horários e geografia do transporte público, adotado universalmente desde a sua criação (<https://gtfs.org>). Um *feed* GTFS é um arquivo comprimido contendo um conjunto de ficheiros TXT/CSV que descrevem, de forma completa, a rede de um operador: paragens, rotas, viagens, horários e calendários de serviço.

Ao contrário dos conjuntos de dados disponibilizados — que medem fluxos observados (presença Vodafone) — os dados GTFS representam a **oferta programada** de transporte, isto é, o serviço que os operadores se comprometeram a prestar segundo os seus horários públicos. Esta distinção é fundamental: a oferta GTFS é constante e determinista por definição, enquanto a afluência observada via C1 é estocástica e sensível a fatores externos.

3.8.2 Operadores e Fontes dos Feeds

Foram descarregados e processados dados de 8 operadores com presença nos terminais em estudo. Para a maioria, o *feed* foi encontrado no portal <https://www.transit.land>. A única exceção foi a Transtejo Soflusa, cujos dados foram obtidos através de uma API própria documentada num repositório do GitHub:

<https://api.transtejo.pt/files/GTFS.zip>. Esta cobertura é, no entanto, parcial no que respeita aos terminais de Campo Grande e Oriente, onde operam outros operadores de autocarro de longo curso e/ou internacional cujos horários não estão disponíveis em formato GTFS nem foram possíveis de obter por outros meios durante o período deste estudo. Acredita-se, porém, que a ausência destes operadores não deverá ter um impacto significativo nas métricas de rotas e viagens analisadas, uma vez que os operadores com maior volume e regularidade de serviço já se encontram representados.

#	Operador	Modo	Interfaces cobertas	GTFS disponível
1	Metro de Lisboa	Metropolitano	Todas as 4 interfaces	Sim
2	CP — Comboios de Portugal	Ferrovário (urbano, regional, longo curso)	Oriente, Sete Rios, Cais do Sodré	Sim
3	Fertagus	Ferrovário (suburbano)	Sete Rios	Sim
4	Carris	Autocarro urbano (Lisboa)	Todas as 4 interfaces	Sim
5	Carris Metropolitana	Autocarro interurbano (AML)	Todas as 4 interfaces	Sim
6	TransTejo Soflusa	Ferry / Fluvial (Rio Tejo)	Cais do Sodré (exclusivo)	Sim
7	FlixBus	Autocarro longo curso (nacional e internacional)	Oriente, Sete Rios	Sim
8	Rede Expressos	Autocarro longo curso (nacional e internacional)	Oriente, Sete Rios	<i>Web Scraping</i>

Nota — Rede Expressos (dados por *web scraping*): A Rede Expressos é o principal operador nacional e internacional de autocarros de longo curso em Portugal, com serviços regulares a partir de Sete Rios e Oriente. Por não disponibilizar *feed* GTFS público, os dados foram recolhidos através de *web scraping* no site oficial (<https://rede-expressos.pt/pt/horarios-bilhetes>) durante o período de 18 a 24 de Abril de 2026 e 1 de Maio de 2026, cobrindo quatro regimes: Sábado (18 Abr), Domingo (19 Abr), Dia Útil (segunda-feira: 20 Abr) e Feriado (1 Mai). Os dados incluem os serviços com partida de Sete Rios e de Oriente, representando tanto a Rede Expressos como as empresas associadas (Mundial Turismo e RENEX). Para uma descrição técnica detalhada do processo de *web scraping* implementado, ver Anexo II.

3.8.3 Principais Considerações

Cobertura temporal: Os *feeds* GTFS descrevem o horário dos anos 2024–2026, enquanto os dados Vodafone, Waze e IPMA cobrem o período de janeiro de 2023 a junho de 2025. A análise de alinhamento oferta–procura assume que os padrões de serviço não variaram substancialmente entre anos, o que é razoável dado que as redes de transporte público de Lisboa têm elevada estabilidade estrutural.

Representação da oferta: O GTFS representa os horários programados, não os realizados. Perturbações, supressões e atrasos não são capturados.

Validade dos *feeds* e dias de referência por regime: Cada operador publica o seu próprio *feed* GTFS com uma janela temporal própria. Para gerar os gráficos de frequência horária, foi necessário eleger um único “dia de referência” representativo de cada regime: uma segunda-feira para o dia útil, um sábado, um domingo e um feriado. Os **regimes de dia** (Dia Útil, Sábado, Domingo, Feriado) são derivados do ficheiro `calendar.txt` de cada *feed*.

Variação intra-semanal (CP e FlixBus): A maior parte dos operadores usa o mesmo programa de serviço em todos os dias úteis da semana. Contudo, a CP e a FlixBus têm algumas rotas que apenas circulam em dias específicos. Os gráficos de dia útil são construídos a partir de uma única segunda-feira de referência, pelo que eventuais serviços exclusivos de quinta ou sexta-feira não ficam representados. O impacto é reduzido: o número de rotas afetadas é pequeno face ao total e os padrões horários gerais não são alterados de forma significativa.

3.8.4 Estrutura dos Ficheiros

Cada *feed* GTFS é um ficheiro ZIP contendo vários ficheiros TXT com estrutura CSV. Os ficheiros utilizados neste projeto foram:

Ficheiro GTFS	Conteúdo relevante para o projeto
<code>stops.txt</code>	Lista de paragens com coordenadas geográficas (latitude, longitude) e nome.
<code>routes.txt</code>	Lista de rotas (linhas) com identificador, nome curto, nome longo e operador.
<code>trips.txt</code>	Lista de viagens: associa cada <i>trip</i> a uma rota e a um calendário de serviço.
<code>stop_times.txt</code>	Horários detalhados: para cada <i>trip</i> , lista todas as paragens com a hora de chegada e de partida. É o ficheiro mais volumoso.
<code>calendar.txt</code>	Define os regimes de serviço (dia útil, sábado, domingo) com datas de início e fim de cada programa.

3.8.5 Conceitos Fundamentais

Conceito	Definição
Rota (<i>Route</i>)	Serviço identificado por nome e número — corresponde à rota ou linha que o passageiro conhece (ex: “Linha Azul” do Metro, “18E – Cais do Sodré – Cemitério Ajuda”). Uma rota define o percurso geral e o operador, mas não especifica quando circula. O número de rotas distintas de uma interface indica a sua diversidade de destinos.
Viagem (<i>Trip</i>)	Execução concreta de uma rota num dia e hora específicos. Um elétrico que parte às 08h14 e outro que parte às 10h26 são <i>trips</i> diferentes. O número total de <i>trips</i> distintos é a medida mais fiel da intensidade de serviço operacional de um terminal , captando a frequência com que o serviço é efetivamente prestado.
Viagens únicas por hora	Métrica derivada: número de <i>trips</i> distintas com hora de partida programada dentro de um dado intervalo de 60 minutos. Esta métrica é a base dos gráficos de frequência horária.

Mapeamento de Conceitos: GTFS ↔ Rede Expressos Os dados da Rede Expressos, recolhidos por *web scraping*, utilizam uma nomenclatura diferente mas conceptualmente equivalente. O campo *departureTripId* identifica um serviço recorrente com hora de partida e corredor fixos — equivalente ao *route_id* do GTFS. O campo *scheduleId* identifica uma concretização única de um serviço — equivalente ao *trip_id* do GTFS.

Conceito	GTFS	Rede Expressos
Rota (Nº Rotas)	<i>route_id</i>	<i>departureTripId</i> (código do serviço recorrente)

Conceito	GTFS	Rede Expressos
Viagem (Nº Trips)	<i>trip_id</i>	<i>scheduleId</i> (concretização única de um serviço)
Calendário	<i>service_id</i>	campo <i>date</i> nos ficheiros JSON obtidos

Em ambos os sistemas, **Nº Rotas** e **Nº Trips** são calculados como contagens globais de identificadores distintos sobre todos os dados disponíveis, sem filtro de data de referência. Esta abordagem é consistente porque, em ambos os sistemas, os identificadores não se multiplicam com o tempo — cada padrão de serviço aparece apenas uma vez, independentemente de quantos dias ou semanas está ativo. A única parte da análise que utiliza datas de referência específicas é a frequência horária, onde tanto o GTFS como a Rede Expressos filtram os dados para um único dia representativo por regime, garantindo comparabilidade direta entre operadores.

3.8.6 Metodologia de Associação Geoespacial

Para associar paragens ou estações/plataformas a cada interface intermodal, foi adotado um **raio de 300 metros** em torno do centróide geográfico de cada terminal, calculado com recurso à distância de Haversine³. Todas as paragens ou estações/plataformas dos operadores dentro deste raio foram incluídas.

A análise da oferta programada — perfil por terminal, operador e regime operacional, e o alinhamento com a afluência observada — encontra-se na secção de Análise dos padrões de mobilidade.

3.9 Conjunto 7 — Overture Maps (Pontos de Interesse)

3.9.1 Descrição Geral

O Overture Maps Foundation⁴ é um projecto de dados geoespaciais abertos criado em 2022 por um consórcio que inclui a Meta, a Microsoft, a Amazon e a TomTom. O seu objectivo é disponibilizar gratuitamente um mapa digital do mundo mais completo e mais actual do que os mapas tradicionais de código aberto. A base de dados de Pontos de Interesse (POI) combina várias fontes distintas — OpenStreetMap (o maior mapa colaborativo do mundo), Meta (locais verificados com interações reais de utilizadores), Microsoft/Bing Places e TomTom — resultando num conjunto com mais de 60 milhões de POI a nível global.

Para este projecto, foram descarregados todos os POI da área metropolitana de Lisboa (bounding box com margem de 1,5 km relativamente a cada terminal), correspondentes ao *snapshot* de abril de 2026, num total de **35.103 locais**. A recolha foi feita através da ferramenta oficial **overturemaps CLI**, com exportação em formato *geoparquet* (6,8 MB).

Limitação importante: Os dados do Overture Maps são um *snapshot* estático — uma fotografia do que existia em abril de 2026. Não reflectem aberturas ou encerramentos anteriores ou posteriores a essa data.

3.9.2 Metodologia de Recolha e Tratamento

Raio de análise O raio de análise escolhido foi de **1000 metros**. Esta decisão tem uma justificação prática: 1000 metros representa aproximadamente 10 a 12 minutos a pé a um ritmo normal — a distância que uma pessoa está disposta a percorrer quando sai de um terminal para o trabalho, faculdade, restaurante ou espaço de lazer.

Classificação dos POI Cada POI do Overture Maps tem uma categoria original (**basic_category**) que segue a taxonomia interna da plataforma — centenas de categorias específicas como **italian_restaurant**, **pharmacy** ou **coworking_space**. Estas foram mapeadas para 10 categorias de análise através de dois métodos

³https://pt.wikipedia.org/wiki/F%C3%B3rmula_de_haversine

⁴<https://overturemaps.org/>

complementares: *matching* exacto (comparação directa com um dicionário construído manualmente) e *matching* por palavra-chave (para categorias não mapeadas). POI cuja categoria não corresponde a nenhuma das 10 definidas são classificados como “Outros” (estacionamentos, estações de transporte, embaixadas, etc.).

Deduplicação O *dataset* do Overture Maps pode conter registos duplicados para o mesmo estabelecimento — situação típica quando a mesma entidade física é importada de múltiplas fontes em simultâneo. Foi aplicada uma etapa de deduplicação com três mecanismos complementares:

- **Duplicados geográficos:** dois POI com nome semelhante e coordenadas próximas são considerados duplicados; o de menor nível de confiança é removido. Este processo é executado de forma independente por terminal, evitando que cadeias de retalho presentes em múltiplos locais sejam incorrectamente eliminadas.
- **Reclassificação:** POI incorrectamente categorizados são movidos para a categoria correcta em vez de removidos.
- **Remoção manual:** entradas inválidas, genéricas ou redundantes identificadas por inspecção (nomes de ruas, entidades sem estabelecimento físico, etc.).

Após a deduplicação, o conjunto de POI utilizado na análise ficou com **7.708 registos** distribuídos pelos quatro terminais no raio de 1000 m.

3.9.3 Categorias de POI

Foram definidas 10 categorias de análise, adaptadas à taxonomia do Overture Maps e ao contexto do projecto:

Categoria	O que representa
Restauração	Restaurantes, cafés, pastelarias, <i>fast food</i> , cantinas e espaços de refeição rápida.
Bares e Vida Nocturna	Bares, pubs, discotecas, karaoke e espaços de lazer nocturno. Atrai afluência tardia (após as 20h) e muito concentrada ao fim de semana.
Comércio / Retalho	Lojas de roupa, calçado e electrónica, supermercados, mercados, centros comerciais e retalho em geral.
Alojamento	Hotéis, <i>hostels</i> , pensões, apart-hotéis e apartamentos turísticos. Reflete a vocação turística ou de negócios do terminal.
Saúde	Hospitais, clínicas, centros de saúde, consultórios dentários, centros de diagnóstico e outros serviços de saúde.
Desporto e Fitness	Ginásios, estúdios de <i>fitness</i> , campos de padel e ténis, pavilhões desportivos, piscinas e outros espaços de actividade física.
Serviços do Quotidiano	Farmácias, bancos e ATM, correios, cabeleireiros, lavandarias, serviços de reparação e outros serviços de proximidade.
Educação	Escolas, universidades, infantários, bibliotecas, centros de formação profissional e estabelecimentos de ensino em geral.
Escritórios e Negócios	Escritórios empresariais, espaços de <i>coworking</i> e serviços profissionais (advogados, contabilistas, consultoras).
Cultura e Entretenimento	Cinemas, museus, galerias de arte, teatros, estádios, parques temáticos, jardins públicos e espaços de lazer cultural.

A título de exemplo, apresenta-se a distribuição espacial dos POI para o terminal do Oriente. O mesmo processo foi aplicado aos restantes três terminais, gerando um mapa interactivo por terminal e um mapa consolidado com todos os terminais em simultâneo.




Figura 11: Distribuição espacial dos POI no terminal do Oriente (raio 1000 m). Cada círculo representa um POI, colorido pela categoria e com tamanho proporcional ao nível de confiança atribuído pelo Overture Maps.

4 Data Preparation

4.1 IPMA

4.1.1 Normalização das Variáveis Temporais e de Identificação da Estação

Numa fase inicial do processo de preparação dos dados meteorológicos, procedeu-se à normalização de algumas variáveis presentes no *dataset* original do IPMA. Em particular, verificou-se que a variável “estacion”, que identifica a estação meteorológica responsável pela observação, se encontrava designada em espanhol. De forma a garantir consistência com o restante conjunto de dados e com a nomenclatura adotada ao longo do trabalho, esta variável foi renomeada para STATION.

Adicionalmente, a variável temporal original “fecha” (também em espanhol), que agregava simultaneamente informação de data e hora, foi convertida para formato *datetime* e utilizada para a criação de um conjunto de variáveis temporais derivadas. Em concreto, foram criadas as seguintes variáveis:

- **DATA** - corresponde à data da observação;
- **HORA** - indica a hora do registo meteorológico;
- **ANO** - identifica o ano da observação;
- **MES** - indica o mês correspondente.

4.1.2 Duplicados

Conforme as análises anteriores, verificou-se a existência de múltiplos registos para a mesma combinação de estação, data e hora, correspondendo a dois tipos distintos de situações.

Por um lado, verificaram-se duplicados reais, em que os registos apresentam os mesmos valores em todas as variáveis meteorológicas. Nestes casos, procedeu-se simplesmente à remoção dos registos redundantes, mantendo apenas uma observação por período e estação.

Por outro lado, identificaram-se situações de “falsos duplicados”, caracterizadas pela coexistência de dois registos diferentes para o mesmo instante temporal: um contendo valores meteorológicos válidos e outro composto exclusivamente por zeros (ou valores nulos). Neste caso, a aplicação direta do método *drop_duplicates*, considerando apenas STATION, DATA e HORA, poderia levar à remoção de observações válidas, uma vez que o *pandas* mantém por defeito a primeira ocorrência encontrada. Assim, esses casos foram interpretados como registos com ausência de medição, sendo, por isso, eliminadas as observações em que todos os valores são nulos ou iguais a zero, mantendo-se os registos com informação efetivamente válida.

4.1.3 Agregação dos Dados Meteorológicos

Após a resolução dos duplicados, procedeu-se à agregação dos dados meteorológicos, com o objetivo de obter uma única observação por período horário. Para tal, foi adotada uma abordagem hierárquica baseada na localização das estações meteorológicas.

1º - Numa primeira etapa, foram consideradas as estações do Geofísico (1200535) e de Gago Coutinho (1200579), por se localizarem em zonas mais centrais da cidade. Sempre que existiam dados disponíveis em ambas, foi calculada a média das variáveis meteorológicas. Caso apenas uma das estações apresentasse dados válidos, utilizou-se diretamente esse valor.

2º - Na ausência de informação nas estações principais, recorreu-se à estação da Tapada da Ajuda (1210762), utilizando os seus registos como alternativa.

3º - Por fim, para os períodos em que não existia informação em nenhuma das estações, aplicou-se o método de interpolação linear, estimando os valores em falta com base nos períodos temporais adjacentes (anteriores e posteriores).

4.1.4 Imputação dos períodos omissos

De forma a garantir a continuidade da série temporal e permitir a realização de análises consistentes, foi necessário proceder à imputação dos 721 períodos horários sem registo identificados anteriormente. Atendendo à heterogeneidade das lacunas temporais, foram adotadas duas abordagens em função da dimensão dos *gaps*:

Períodos curtos: para as lacunas de curta duração (até 6 horas), foi aplicada a técnica de interpolação linear, assumindo uma variação gradual das variáveis meteorológicas entre períodos consecutivos. Esta abordagem revelou-se adequada para este tipo de falhas, permitindo estimar valores desconhecidos sem introduzir distorções significativas na série temporal.

Períodos longos: para os períodos com falhas prolongadas (superiores a 10 horas), a interpolação linear foi considerada inadequada, uma vez que poderia originar estimativas pouco realistas, especialmente em variáveis com elevada variabilidade, como a precipitação ou a intensidade do vento. Nestes casos, optou-se por uma abordagem baseada no contexto temporal, recorrendo a médias históricas condicionadas à hora do dia e ao mês. Esta metodologia permite capturar padrões sazonais e horários típicos das variáveis meteorológicas, conduzindo a estimativas mais robustas.

4.1.5 Feature Engineering

Com o objetivo de enriquecer o conjunto de dados e facilitar a análise do impacto das condições meteorológicas nos padrões de mobilidade, tendo em consideração os objetivos definidos, procedeu-se à criação de novas variáveis derivadas das já existentes. Foram definidas as seguintes variáveis:

- **IS_CHUVA (binária)** - indica a ocorrência de precipitação, assumindo valor 1 quando a variável `PREC_ACUMULADA` é superior a zero e 0 caso contrário;
- **INTENSIDADE_CHUVA (categórica ordinal)** - classifica a intensidade da precipitação registada, permitindo distinguir diferentes níveis de chuva. Esta variável assume valor 1 quando ocorre chuva fraca (precipitação inferior a 0,5 mm), 2 quando ocorre chuva moderada (precipitação entre 0,5 mm e 4 mm) e 3 quando ocorre chuva forte (precipitação igual ou superior a 4 mm);
- **TEMPERATURA_EXTREMA (binária)** - sinaliza condições térmicas extremas, assumindo valor 1 quando a temperatura é inferior a 5°C ou superior a 35°C, e 0 caso contrário.

Estas variáveis permitem simplificar a interpretação das condições meteorológicas, nomeadamente a influência de eventos extremos (chuva intensa ou temperaturas elevadas/baixas) no comportamento da mobilidade urbana.

4.1.6 Ajuste da Granularidade Temporal dos Dados Meteorológicos

Os dados meteorológicos disponibilizados pelo IPMA apresentam uma granularidade temporal horária, isto é, cada observação corresponde a um intervalo de uma hora. No entanto, os dados de mobilidade provenientes da Vodafone Grelha encontram-se estruturados em intervalos de 5 minutos.

Para permitir a integração entre os diferentes conjuntos de dados, tornou-se necessário ajustar a granularidade temporal das observações meteorológicas, de forma a que estas coincidissem com a estrutura temporal dos dados de mobilidade.

Para esse efeito, procedeu-se a uma reamostragem temporal (*resampling*) em intervalos de 5 minutos. Como as variáveis meteorológicas apenas estão disponíveis à escala horária, os valores foram replicados para os intervalos intermédios utilizando o método *forward fill*, que propaga o último valor observado para os instantes seguintes até à ocorrência de uma nova observação.

Desta forma, cada registo meteorológico passou a representar não apenas o instante da observação original, mas também os intervalos de 5 minutos subsequentes dentro da mesma hora. Este procedimento permitiu igualar a granularidade temporal da Vodafone Grelha, assegurando que cada instante temporal dos dados de mobilidade possui informação meteorológica associada.

4.2 Eventos Desportivos (Jogos de Futebol)

4.2.1 Normalização dos Dados

Após a filtragem, procedeu-se à normalização dos nomes dos estádios, uma vez que estes surgiam com diferentes designações nos ficheiros originais (por exemplo, “SL Benfica”, “Estádio do Sport Lisboa e Benfica”, “Estádio do SL Benfica” ou “José Alvalade”). Estas designações foram uniformizadas em duas categorias principais:

- Estádio da Luz
- Estádio José Alvalade

Desta forma, garante-se a consistência da variável de localização, permitindo, se necessário, distinguir os jogos realizados em cada estádio e avaliar o seu impacto nos padrões de mobilidade de terminais específicos.

Adicionalmente, foi realizada uma correção em alguns registos cuja hora de início dos jogos se encontrava desfasada devido ao fuso horário (jogos registados às 19h foram ajustados para as 20h), de forma a garantir maior consistência temporal.

4.2.2 Transformação das Variáveis Temporais

A variável original *Date* foi convertida para o formato *datetime*, permitindo a sua manipulação e desagregação. A partir desta variável foram criadas:

- **DATA** - data do jogo
- **HORA** - hora de início do jogo

Foi ainda criada a variável:

- **HORA_FIM** - correspondente à hora aproximada do fim do jogo, assumindo uma duração aproximada de 2 horas.

4.2.3 Construção de Variáveis Temporais

Com base nas variáveis anteriores, foram criados *timestamps* auxiliares para facilitar a futura integração com os dados de mobilidade da Vodafone:

- **DATETIME_INICIO** - instante exato do início do jogo
- **DATETIME_FIM** - instante estimado do fim do jogo

Adicionalmente, foram definidas janelas temporais de interesse associadas a cada evento:

- **INICIO_JANELA** - 2 horas antes do início do jogo
- **FIM_JANELA** - 1 hora após o fim do jogo

Estas janelas permitem capturar períodos relevantes de afluência de público, sendo fundamentais para análises posteriores sobre o impacto dos eventos nos fluxos de mobilidade.

4.3 Vodafone Grelha

O tratamento do dataset Vodafone Grelha envolveu várias etapas de preparação, transformação e criação de variáveis, com o objetivo de adequar os dados às necessidades da análise. Numa fase inicial, os anos de estudo (2023, 2024 e 2025) foram divididos pelos elementos do grupo, permitindo o processamento paralelo da informação.

4.3.1 Filtragem Espacial

Em primeiro lugar, foi efetuada uma filtragem espacial, mantendo apenas as quadrículas (*grids*) associadas às áreas de estudo previamente definidas: Cais do Sodré, Sete Rios, Campo Grande e Oriente. Assim, foram

descartadas as observações (Vodafone Grelha) provenientes de outras áreas da cidade que não eram relevantes para os objetivos da investigação.

Este processo resultou numa diminuição significativa do conjunto de dados, pois passámos a trabalhar com apenas 21 das 3743 quadrículas do município de Lisboa (redução $\approx 99\%$). Em termos absolutos, o número de registos diminuiu de 921 514 352 para 5 173 114, o que se traduziu numa redução do volume de dados de 137 GB para 440 MB.

4.3.2 Normalização das Variáveis

Procedeu-se também à normalização dos nomes das variáveis, convertendo-os para letras maiúsculas e uniformizando a variável temporal para DATETIME. As variáveis de contagem de dispositivos (C1, C3, C5 e C6), inicialmente representadas por números decimais, foram arredondadas, de forma a garantir coerência com a sua natureza discreta.

4.3.3 Ajuste do Fuso Horário e Conversão para Hora Local

Durante o processo de compreensão dos dados da Vodafone Grelha, verificou-se que a variável temporal DATETIME se encontrava registada em formato UTC (*Coordinated Universal Time*), identificado pela presença do sufixo *Z* nos *timestamps*. Este formato representa o tempo universal coordenado e não corresponde diretamente à hora local de Portugal continental.

Uma vez que a análise realizada neste estudo pretende refletir os padrões reais de mobilidade urbana na cidade de Lisboa, tornou-se necessário converter estes registos para a hora local, tendo em consideração as alterações associadas ao horário de verão (adiantamento de uma hora).

Para esse efeito, foi aplicada uma conversão de fuso horário utilizando a biblioteca *pandas*, através do método:

```
.dt.tz_convert("Europe/Lisbon")
```

Esta operação permitiu transformar os *timestamps* originalmente registados em UTC para o fuso horário correspondente a Lisboa, garantindo que as observações passam a refletir corretamente a hora local. Importa salientar que esta conversão é efetuada de forma automática pela biblioteca, considerando as transições entre horário de inverno (UTC+0) e horário de verão (UTC+1).

Desta forma, garante-se que as análises subsequentes — como a identificação de horas de ponta, o estudo do impacto de eventos desportivos e da influência das condições meteorológicas — são realizadas com base em referências temporais corretas e comparáveis.

4.3.4 Criação de Variáveis Temporais e Estruturais

A partir da variável DATETIME, foram geradas novas variáveis temporais, nomeadamente DATA, ANO, MES e HORA, possibilitando uma análise mais detalhada dos padrões ao longo do tempo. Foi ainda criada a variável TERMINAL, permitindo associar cada GRID_ID ao respetivo terminal intermodal em estudo.

4.3.5 Feature Engineering

De forma a enriquecer o conjunto de dados da Vodafone Grelha e dar resposta às questões colocadas, foram criadas novas variáveis. Estas variáveis permitem capturar efeitos associados ao calendário, ao dia da semana e a períodos específicos do ano que podem influenciar a utilização dos transportes públicos:

- **HORA_INT (numérica discreta)** - variável derivada a partir da variável temporal DATETIME, que identifica a hora inteira ("em ponto") correspondente ao momento da observação. A criação desta variável permite analisar padrões de mobilidade ao longo das diferentes horas do dia, nomeadamente na identificação de períodos de maior intensidade de deslocações urbanas, mantendo simultaneamente a granularidade temporal original dos dados, que corresponde a registos de cinco em cinco minutos;
- **IS_HORA_PONTA (binária)** - identifica períodos horários tradicionalmente associados a maior intensidade de deslocações urbanas. Esta variável assume valor 1 no período entre as 7 e as 10 da manhã

e entre as 17 e as 20 da noite, correspondendo aos períodos típicos de entrada e saída do trabalho/escola, e valor 0 nas restantes horas. **Nota:** Estes intervalos foram definidos com base num desafio lançado pelo próprio LxDataLab em 2023, sobre os padrões de mobilidade na cidade de Lisboa, realizado a partir de dados de dispositivos móveis⁵;

- **DIA_SEMANA (categórica)** - derivada a partir da data, identifica o dia da semana correspondente;
- **IS_FIM_DE_SEMANA (binária)** - com base no dia da semana, assume valor 1 quando o dia corresponde a sábado ou domingo, e 0 nos restantes dias;
- **IS_PERIODO_LETIVO (binária)** - identifica os dias pertencentes ao período letivo definidos para os anos de 2023, 2024 e 2025, excluindo os períodos de interrupção escolar, como as férias de Natal, Carnaval, Páscoa e o período de férias de verão;
- **IS_FERIADO (binária)** - indica se uma determinada data corresponde a um feriado nacional em Portugal;
- **IS_VESPERA_FERIADO e IS_POS_FERIADO (binárias)** - identificam, respetivamente, os dias imediatamente anteriores e posteriores a um feriado;
- **IS_PONTE (binária)** - assume valor 1 nos dias em que ocorre uma situação de ponte, isto é, quando existe um dia útil entre um feriado e o fim de semana (tipicamente quando o feriado ocorre à terça-feira ou à quinta-feira).

4.3.6 Integração dos Dados Eventos Desportivos

Com o objetivo de avaliar o impacto dos eventos desportivos nos padrões de mobilidade urbana, procedeu-se à integração da fonte de dados relativa aos jogos de futebol realizados em Lisboa com o *dataset* da Vodafone Grelha

Integração dos Datasets

Definição da variável IS_JOGO

Com base nas janelas temporais definidas para cada jogo (período entre duas horas antes do início e uma hora após o término), foi criada a variável binária IS_JOGO, com o objetivo de identificar períodos potencialmente influenciados pelos eventos desportivos. A construção desta variável seguiu os seguintes critérios:

- **IS_JOGO = 1** quando o instante temporal se encontra: nas duas horas anteriores ao início do jogo ou na hora imediatamente posterior ao seu término;
- **IS_JOGO = 0** quando o instante corresponde: ao período durante o jogo ou a qualquer outro momento fora das janelas definidas.

A exclusão do período durante o jogo prende-se com o facto de se pretender capturar essencialmente os efeitos de concentração e dispersão de fluxos (antes e depois do evento), que são os momentos de maior impacto na mobilidade.

Definição da variável LOCAL_JOGO

Com o objetivo de distinguir a localização dos jogos de futebol considerados no estudo, foi criada a variável categórica LOCAL_JOGO. Esta variável permite identificar em que estádio ocorreu cada evento desportivo, possibilitando analisar potenciais diferenças no impacto na mobilidade em cada um dos terminais.

A construção desta variável seguiu os seguintes critérios:

- **LOCAL_JOGO = 0** quando não existe qualquer jogo de futebol associado ao período temporal considerado;
- **LOCAL_JOGO = 1** quando o jogo ocorre no **Estádio da Luz**;

⁵<https://www.worlddataleague.com/post/determining-the-main-mobility-flows-in-lisbon-based-on-mobile-device-data>

- **LOCAL_JOGO = 2** quando o jogo ocorre no **Estádio José Alvalade**.

A introdução desta variável permite incorporar a dimensão espacial dos eventos desportivos na análise, possibilitando avaliar se os impactos observados na mobilidade diferem consoante o estádio onde o jogo é realizado.

4.3.7 Análise e Tratamento de Outliers da Variável C1

A variável C1 foi submetida a um processo detalhado de análise e tratamento de *outliers*, desenvolvido em dois *notebooks* sequenciais. O processo, descrito em detalhe no Anexo III, envolveu: (i) a identificação e remoção de *outliers* óbvios através de análise IQR por terminal; e (ii) a validação da legitimidade dos *fliers* residuais através de um sistema de *scoring* multi-critério que classifica cada registo como *provável legítimo*, *duvidoso* ou *provável erro*.

4.3.8 Estratégia de Tratamento Adotada

Com base nos resultados obtidos, foi adotado o **Cenário B** como *baseline* para todas as análises subsequentes do projeto:

- Remoção dos 13 *outliers* óbvios previamente identificados;
- Remoção dos 12 214 registos classificados como *provável erro*;
- Remoção dos 19 170 registos classificados como *duvidosos*;
- Manutenção dos 179 158 registos *prováveis legítimos* no conjunto de análise.

Justificação: A opção pelo Cenário B assenta numa postura de prudência que procura preservar os padrões de mobilidade *atipicamente comuns* (eventos reais) e, simultaneamente, eliminar o ruído que comprometeria a qualidade das análises.

O resultado desta operação de limpeza é o seguinte:

- **Nº Registos iniciais:** 5 172 631
- **Nº Registos removidos:** 31 397
- **Nº Registos finais:** 5 141 233

Terminal	Nº Registos	%
Cais do Sodré	1 961 205	38,1%
Sete Rios	1 232 050	24,0%
Campo Grande	983 994	19,1%
Oriente	963 984	18,8%

4.4 Waze

4.4.1 Filtragem das Ocorrências do Waze

Para garantir que a análise se concentra nas zonas mais relevantes para o estudo, foi necessário realizar uma filtragem das ocorrências de congestionamento do Waze com base na proximidade às quatro interfaces de transporte em análise: *Cais do Sodré*, *Campo Grande*, *Sete Rios* e *Oriente*.

Inicialmente, cada terminal foi associado a um conjunto específico de áreas geográficas (quadrículas) que representam a sua localização e área envolvente próxima. Estas áreas permitiram definir, de forma consistente, as zonas urbanas onde é mais provável de existir uma maior concentração de tráfego associada a cada terminal.

De seguida, foi definida uma **zona de influência** em torno dessas áreas, considerando uma distância máxima de **500 metros** a partir dos limites de cada terminal. Assim, apenas as ocorrências de congestionamento localizadas dentro desse raio foram consideradas relevantes para o estudo.

Em termos práticos, isto significa que:

"Uma ocorrência foi incluída na base de dados final se ocorreu até 500 metros do terminal analisado correspondente."

Cada ocorrência foi então atribuída ao terminal correspondente dentro do limite dessa zona de influência.

O resultado deste processo foi um novo conjunto de dados contendo apenas os congestionamentos associados às áreas dos terminais selecionados.

4.4.2 Ajuste do Fuso Horário e Conversão para Hora Local

À semelhança do que foi realizado para os dados de mobilidade da Vodafone Grelha (ver Secção 11.3.3), também nos dados do Waze foi necessário proceder à conversão do fuso horário.

Os *timestamps* encontravam-se registados em formato UTC, tendo sido aplicada a conversão para o fuso horário *Europe/Lisbon* através da biblioteca *pandas*. Este procedimento garante a consistência temporal entre os diferentes conjuntos de dados utilizados no estudo.

4.4.3 Conversão e Tratamento da Variável SPEED

A variável SPEED, originalmente registada em metros por segundo, foi convertida para quilómetros por hora através da multiplicação dos valores por 3,6. Este procedimento permitiu trabalhar com unidades mais intuitivas e compatíveis com a análise do comportamento do tráfego.

4.5 GTFS

O tratamento dos dados GTFS centrou-se essencialmente na associação geoespacial das paragens e estações a cada terminal intermodal, conforme descrito na Secção 3.8.6. Em síntese, foram retidas todas as paragens/-plataformas de cada operador situadas num raio de 300 metros do centróide de cada interface, utilizando a distância de Haversine para garantir precisão geográfica. A partir deste conjunto filtrado, foram calculadas as métricas de oferta horária (viagens únicas por hora) para cada terminal e para cada regime operacional (Dia Útil, Sábado, Domingo e Feriado), que constituem os dados de oferta utilizados na análise de alinhamento com a afluência C1.

4.6 Integração dos Datasets

Após todo o processamento necessário em cada um dos conjuntos de dados, foi então realizada a junção dos diferentes *datasets* — nomeadamente **Vodafone Grelha**, **IPMA**, **Waze** e **Eventos Desportivos** — num único *dataframe*. Os dados GTFS, pela sua natureza de oferta programada (e não de série temporal contínua com a mesma granularidade), são utilizados como referência analítica e não foram fundidos diretamente no *dataframe* integrado.

Esta integração permitiu juntar informações provenientes de diferentes fontes, incluindo dados de mobilidade, condições meteorológicas, congestionamento rodoviário e ocorrência de eventos desportivos, tornando possível uma análise conjunta dos fatores que influenciam o comportamento da mobilidade urbana.

O processo de integração foi realizado com base em variáveis comuns, principalmente a dimensão temporal (DATA, HORA e DATETIME) e a dimensão espacial (GRID_ID e TERMINAL). Desta forma, cada observação passou a representar um determinado instante temporal e uma localização específica, contendo simultaneamente informação sobre tráfego rodoviário, condições meteorológicas e contexto urbano.

Nota: Uma vez que os diferentes conjuntos de dados não apresentam exatamente o mesmo período temporal de cobertura, foi necessário limitar o intervalo de análise ao período comum a todas as fontes. Assim, os dados foram considerados até às **23h00 do dia 30 de junho**, correspondendo ao último instante temporal

para o qual existe informação disponível em todos os *datasets*. Esta restrição garante a consistência temporal da base de dados integrada e evita a presença de valores em falta resultantes da ausência de dados em alguma das fontes.

A base de dados final resultante desta integração é constituída por 5 172 631 registos de 32 variáveis apresentadas na tabela seguinte, organizadas de forma a permitir a análise conjunta das diferentes dimensões consideradas no estudo.

Campo	Tipo	Descrição
GRID_ID	Numérico	Identificador da quadrícula geográfica associada ao terminal
TERMINAL	String	Nome do terminal associado à quadrícula (Cais do Sodré, Campo Grande, Sete Rios ou Oriente)
C1, C3, C5, C6	Numérico	Indicadores de mobilidade provenientes dos dados da Vodafone, representando a intensidade de presença de dispositivos móveis na área
DATA	Date	Data correspondente à observação
ANO	Numérico	Ano da observação
MES	Numérico	Mês da observação
HORA	Time	Hora exata correspondente à observação
HORA_INT	Numérico	Hora em formato inteiro (0–23), utilizada para facilitar análises temporais e modelação
IS_HORA_PONTA	Binário	Indicador de período de hora de ponta
DIA_SEMANA	String	Dia da semana correspondente à observação
IS_FIM_DE_SEMANA	Binário	Indicador de fim de semana
IS_PERIODO_LETIVO	Binário	Indicador de período letivo escolar
IS_FERIADO	Binário	Indicador de feriado nacional
IS_VESPERA_FERIADO	Binário	Indicador de véspera de feriado
IS_POS_FERIADO	Binário	Indicador de dia imediatamente após feriado
IS_PONTE	Binário	Indicador de ocorrência de ponte (dia útil entre feriado e fim de semana)
IS_JOGO	Binário	Indicador de ocorrência de evento desportivo (jogo de futebol) no período considerado
LOCAL_JOGO	Categórico	Identifica a localização (estádio) do evento desportivo associado ao período considerado
HUMIDADE	Numérico	Humidade relativa do ar, expressa em percentagem (%)
INTENSIDADE_DO_VENTO_KM	Numérico	Intensidade do vento medida em quilómetros por hora (km/h)
PREC_ACUMULADA	Numérico	Precipitação acumulada medida em milímetros (mm)
TEMPERATURA	Numérico	Temperatura do ar medida em graus Celsius (°C)
IS_CHUVA	Binário	Indicador de ocorrência de precipitação

Campo	Tipo	Descrição
INTENSIDADE_CHUVA	Categórico ordinal (1-3)	Classifica a intensidade da precipitação registada, distinguindo entre chuva fraca, moderada e forte.
TEMPERATURA_EXTREMA	Binário	Indicador de ocorrência de valores extremos de temperatura
DELAY	Numérico	Atraso médio associado ao congestionamento
LENGTH	Numérico	Comprimento médio do congestionamento, em metros
SPEED	Numérico	Velocidade média de circulação na via, em quilómetros por hora (km/h)
LEVEL	Categórico ordinal (0-5)	Nível de gravidade do congestionamento, variando de 0 (fluxo livre) a 5 (via bloqueada)

Esta base de dados encontra-se, assim, preparada para a realização de análises exploratórias, construção de representações gráficas e desenvolvimento de modelos estatísticos, de acordo com os objetivos definidos no estudo. Em particular, permite avaliar o impacto de fatores como condições meteorológicas, períodos do calendário e eventos desportivos nos níveis de congestionamento e padrões de mobilidade urbana.

Deste modo, o *dataset* integrado constitui o ponto de partida para a fase seguinte do trabalho, correspondente à análise conjunta dos dados e à modelação estatística.

4.7 Tratamento de Períodos sem Dados

Foram identificados diversos períodos consecutivos em que todos os indicadores de mobilidade (C1, C3, C5, C6) assumem simultaneamente o valor zero. Estes casos podem estar associados a situações de indisponibilidade do sistema de recolha de dados, não refletindo necessariamente ausência real de fluxo.

	TERMINAL	grupo	DATA_INICIO	HORA_INICIO	DATA_FIM	HORA_FIM	N_INTERVALOS	DURACAO_HORAS
293	CAIS DO SODRE	408	2023-07-28	00:00	2023-07-28	11:55	1152	96.00
354	CAIS DO SODRE	710	2023-10-29	12:40	2023-10-29	17:15	426	35.50
356	CAIS DO SODRE	714	2023-10-29	17:25	2023-10-30	10:10	424	35.33
710	CAIS DO SODRE	1422	2024-02-02	19:15	2024-02-07	15:25	9423	785.25
760	CAIS DO SODRE	1522	2024-03-05	03:40	2024-03-05	09:45	560	46.67
942	CAIS DO SODRE	1886	2024-04-16	13:20	2024-04-16	19:25	577	48.08
3627	CAIS DO SODRE	7256	2024-10-27	03:30	2024-10-27	11:35	404	33.67
5644	CAIS DO SODRE	11290	2024-12-13	01:50	2024-12-17	15:30	8141	678.42
15286	CAMPO GRANDE	104	2023-07-28	00:00	2023-07-28	11:55	576	48.00
15328	CAMPO GRANDE	188	2023-10-29	12:05	2023-10-30	10:10	478	39.83
15338	CAMPO GRANDE	208	2024-02-02	19:15	2024-02-07	15:20	4562	380.17
15340	CAMPO GRANDE	212	2024-03-05	01:00	2024-03-05	09:40	417	34.75
15374	CAMPO GRANDE	280	2024-12-13	01:45	2024-12-17	15:30	4076	339.67
15485	ORIENTE	16	2023-07-28	00:00	2023-07-28	11:55	576	48.00
15487	ORIENTE	20	2023-10-29	12:05	2023-10-30	10:10	479	39.92
15494	ORIENTE	34	2024-02-02	19:30	2024-02-07	15:20	4702	391.83
15571	ORIENTE	188	2024-12-13	05:50	2024-12-17	15:30	4048	337.33
15662	SETE RIOS	158	2023-07-28	00:00	2023-07-28	11:55	720	60.00
15670	SETE RIOS	174	2023-10-29	12:05	2023-10-30	10:10	598	49.83
15673	SETE RIOS	180	2024-02-02	19:15	2024-02-07	15:20	5895	491.25
15675	SETE RIOS	184	2024-03-05	01:00	2024-03-05	09:40	525	43.75
15684	SETE RIOS	202	2024-04-16	13:25	2024-04-16	19:20	357	29.75
15805	SETE RIOS	444	2024-12-13	02:00	2024-12-17	15:30	5080	423.33

Figura 12: Períodos consecutivos com ausência total de fluxo registado dos terminais

Optou-se por não remover estes registos da base de dados, de forma a preservar a integridade temporal da série e evitar a introdução de descontinuidades artificiais.

Ainda assim, para efeitos analíticos, estes períodos são devidamente sinalizados através da variável indicadora *SEM_DADOS*, sendo excluídos das análises sempre que aplicável, considerando apenas observações para as quais *SEM_DADOS* == False.

5 Modeling — Análises dos Padrões Temporais, Fatores Externos, Oferta dos Operadores dos Terminais e o seu Contexto Urbano

Nesta secção apresentam-se as principais análises realizadas com o objetivo de caracterizar os padrões de mobilidade nos principais terminais da cidade de Lisboa e compreender de que forma estes são influenciados por diferentes fatores externos.

A análise incide sobretudo na comparação de diferentes contextos temporais (horas de ponta, feriados, férias), bem como fatores externos como as condições meteorológicas (chuva e temperaturas extremas), tráfego rodoviário e ocorrência de jogos de futebol.

Para a caracterização da mobilidade, a principal variável de mobilidade é a **C1**, que representa o número de utilizadores únicos observados em cada quadrícula num determinado instante temporal. Esta variável permite obter uma estimativa direta da presença de pessoas nas áreas associadas a cada terminal.

Embora o conjunto de dados disponibilize também os contadores **C5** e **C6**, que representam respetivamente o número de entradas e saídas numa determinada quadrícula, estes valores podem incluir movimentos de dispositivos entre quadrículas pertencentes ao mesmo terminal. Assim, nem sempre correspondem a entradas ou saídas efetivas do terminal, podendo introduzir algum viés na interpretação dos fluxos de passageiros. Por este motivo, a variável **C1** é utilizada como principal indicador de mobilidade ao longo das análises apresentadas. As variáveis **C5** e **C6** são consideradas apenas como indicadores complementares, fornecendo uma visão geral da mobilidade, mas não devendo ser interpretadas diretamente como medidas fiéis de entradas ou saídas nos terminais.

Nas subsecções seguintes são apresentadas as diferentes análises realizadas, organizadas de acordo com os principais fatores estudados.

5.1 Dimensões Temporais

Nesta subsecção analisa-se a variação temporal dos padrões de mobilidade nos terminais em estudo, com o objetivo de caracterizar a intensidade e evolução da presença de utilizadores ao longo do tempo.

Neste contexto, são exploradas diferentes dimensões temporais, nomeadamente as variações ao longo do dia, as diferenças entre dias úteis, fins de semana e feriados, bem como efeitos sazonais associados a períodos de férias.

Comparação da Mobilidade entre Hora de Ponta e Fora de Ponta




Figura 13: Entradas e saídas médias por terminal: Horas de ponta vs Fora de ponta

Observa-se um aumento consistente da atividade durante as horas de ponta em todos os terminais, evidenciado por valores médios superiores tanto em entradas como em saídas. Este padrão é particularmente acentuado no terminal do Oriente, que apresenta os maiores níveis de mobilidade, com diferenças expressivas entre períodos ($\Delta = 206$ nas entradas e $\Delta = 141$ nas saídas).

Os terminais de Campo Grande e Sete Rios apresentam igualmente variações relevantes, embora menos acentuadas, indicando uma sensibilidade moderada aos ciclos diários de mobilidade. Por outro lado, o Cais do Sodré revela variações reduzidas, sugerindo um perfil de utilização mais estável ao longo do dia.

Ainda que os indicadores C5 e C6 permitam identificar tendências gerais da variação temporal da mobilidade, importa recordar que estes podem incluir movimentos internos entre quadrículas pertencentes ao mesmo terminal, não correspondendo exclusivamente a entradas e saídas efetivas. Assim, os resultados apresentados devem ser interpretados sobretudo como indicadores da intensidade relativa da mobilidade entre períodos.

Neste contexto, a variável C1 assume particular relevância como principal indicador da dinâmica de mobilidade, permitindo analisar a variação da presença de utilizadores nas áreas envolventes dos terminais ao longo do dia. Desta forma, a análise centra-se sobretudo na intensidade da ocupação dos diferentes espaços, utilizada como uma aproximação indireta dos fluxos de mobilidade.




Figura 14: Fluxo médio de dispositivos (C1): Horas de ponta vs Fora de ponta

Os resultados obtidos confirmam os padrões anteriormente identificados. O terminal do Oriente mantém-se como o principal polo de mobilidade, registrando a maior diferença entre períodos ($\Delta = 287$), o que evidencia uma forte concentração de utilizadores durante as horas de ponta.

Sete Rios e Campo Grande apresentam também reduções visíveis fora dos períodos de maior procura, enquanto o Cais do Sodré mantém valores praticamente constantes entre os dois períodos ($\Delta \approx -1$), sugerindo um perfil de utilização mais homogênea ao longo do dia.

Sendo a variável C1 uma medida mais direta da presença de utilizadores, estes resultados reforçam a robustez das conclusões obtidas anteriormente, confirmando a existência de padrões temporais distintos na dinâmica de mobilidade dos diferentes terminais.

Comparação da Mobilidade entre Dias Úteis e Fins de Semana

Neste contexto, analisa-se a distinção entre dias úteis e fins de semana, procurando identificar alterações na intensidade da presença de utilizadores e nos comportamentos de mobilidade associados.




Figura 15: Fluxo médio de dispositivos (C1) por hora: Dias úteis vs Fins de semana

Nos dias úteis observa-se um padrão típico de mobilidade pendular, caracterizado por um aumento acentuado do fluxo nas primeiras horas da manhã, seguido de um segundo pico ao final da tarde. Estes períodos correspondem às horas de ponta associadas às deslocações casa–trabalho e casa–escola. Este comportamento é particularmente evidente nos terminais de Oriente e Campo Grande, que apresentam variações mais pronunciadas ao longo do dia.

Por contraste, os fins de semana apresentam níveis de fluxo globalmente inferiores e uma distribuição mais uniforme ao longo do dia, sem picos tão marcados. No entanto, no terminal do Cais do Sodré constitui a principal exceção, apresentando um aumento relativo da atividade entre o final do dia e a madrugada, sugerindo maior influência de atividades de lazer e vida noturna.

Para complementar esta análise, a figura seguinte apresenta mapas de calor da intensidade média de mobilidade (C1) por hora e dia da semana. Esta representação permite observar com maior detalhe a evolução temporal da presença de utilizadores ao longo da semana, evidenciando diferenças entre períodos do dia e tipos de dia.




Figura 16: Mapas de calor da intensidade média de mobilidade (C1) por hora e dia da semana nos terminais

Os terminais de Oriente, Campo Grande e Sete Rios apresentam comportamentos típicos de mobilidade pendular, com aumentos expressivos da intensidade de fluxo durante os períodos da manhã e final da tarde nos dias úteis. Estes padrões sugerem uma forte associação a deslocações regulares relacionadas com trabalho, estudo e utilização quotidiana da rede de transportes públicos. Durante o fim de semana, observa-se uma redução global da intensidade de mobilidade, acompanhada por uma distribuição horária menos concentrada nos períodos das horas de ponta.

O Oriente destaca-se pela elevada intensidade de utilização ao longo de quase todo o período diurno, refletindo a sua função enquanto principal interface multimodal da cidade e a diversidade funcional da área envolvente, incluindo áreas comerciais (Vasco da Gama), empresariais e de lazer (Parque das Nações).

Novamente, o terminal do Cais do Sodré apresenta um padrão distinto dos restantes terminais. Embora mantenha níveis elevados de utilização durante o período diurno, observa-se igualmente uma intensidade significativa de mobilidade durante o período noturno e a madrugada, particularmente às sextas-feiras e fins de semana. Destaca-se, em especial, o aumento expressivo da atividade a partir das 21h nas noites de sexta-feira, prolongando-se pelas horas seguintes. Este comportamento poderá estar relacionado com a forte componente de lazer e vida noturna associada à zona envolvente, caracterizada pela presença de bares, restaurantes, clubes e espaços de entretenimento amplamente frequentados durante a noite.

Em conjunto, os resultados evidenciam que os padrões temporais de mobilidade variam não apenas em função do tipo de dia, mas também de acordo com o contexto urbano e funcional associado a cada terminal, refletindo diferentes dinâmicas de utilização do espaço urbano ao longo da semana.

Comparação da Mobilidade entre Período Letivo e Período de Férias

Complementando as análises anteriores, analisa-se de seguida o impacto da sazonalidade na dinâmica de mobilidade, através da comparação entre períodos letivos e períodos de férias. Esta análise permite observar de que forma a redução das deslocações regulares pode influenciar a intensidade de utilização dos diferentes terminais.




Figura 17: Fluxo médio de dispositivos (C1) por hora: Período letivo vs Período de férias

De modo geral, observa-se uma redução da intensidade da mobilidade durante os períodos de férias, sendo este efeito mais evidente nas horas de ponta da manhã, associadas às deslocações pendulares. De forma consistente entre todos os terminais, as reduções máximas ocorrem na hora de ponta matinal, evidenciando o forte impacto da interrupção das atividades escolares e profissionais.

O terminal de Campo Grande foi aquele que evidencia a maior redução relativa entre os períodos analisados, atingindo uma redução máxima diária de aproximadamente 35% sobretudo na hora de ponta de manhã. Este comportamento pode estar associado à forte componente pendular da zona envolvente, caracterizada pela presença de várias instituições de ensino, escritórios, e outros espaços relacionados com académicas e profissionais, refletindo uma elevada influência das deslocações quotidianas relacionadas com trabalho e estudo na utilização deste terminal.

Embora os dados disponíveis não continham informação sobre o perfil dos passageiros, os padrões observados permitem levantar a hipótese de que uma parte significativa dos utilizadores deste terminal seja composta por estudantes, sobretudo devido à forte quebra registada em períodos associados à interrupção das atividades letivas. Ainda assim, esta interpretação deve ser encarada com cautela, uma vez que não pode ser diretamente confirmada pelos dados fornecidos.

No Oriente observa-se igualmente uma redução relevante do fluxo durante as férias, embora menos acentuada (20,1%). O padrão identificado reforça a importância deste terminal enquanto interface associado a deslocações pendulares e atividades profissionais, mantendo ainda assim níveis elevados de utilização ao longo do dia.

O terminal de Sete Rios apresenta uma redução intermédia (cerca de 19%), com um padrão semelhante, mas menos intenso, indicando uma utilização mais equilibrada entre diferentes tipos de mobilidade. Por sua vez, o Cais do Sodr  registra a menor redu  o (cerca de 17%), evidenciando maior estabilidade do fluxo ao longo do dia, possivelmente associada a atividades de lazer, turismo e mobilidade menos dependente de hor rios fixos.

Em termos globais, estes resultados mostram que os terminais mais dependentes de mobilidade pendular s o tamb m os mais sens veis ao per odo de f rias.




Figura 18: Redução percentual do fluxo durante as férias

A análise da redução percentual média do fluxo durante o período de férias reforça este padrão, evidenciando de forma clara que o terminal de Campo Grande é o mais afetado, com uma diminuição média de aproximadamente 17,7%, bastante superior à dos restantes terminais. Em comparação, o Cais do Sodré, Sete Rios e Oriente apresentam reduções significativamente inferiores, confirmando que o impacto das férias é particularmente mais intenso em contextos fortemente associados a mobilidade pendular.

Este resultado consolida a evidência de que o Campo Grande apresenta uma maior dependência de deslocações regulares relacionadas com atividades académicas e profissionais, sendo consequentemente mais sensível a quebras na procura durante períodos não letivos.

Comparação da Mobilidade entre Dias normais e Período de Feriados

Nesta subsecção analisa-se o impacto dos efeitos de calendário na mobilidade, comparando diferentes tipos de dia com base na variação percentual do fluxo face a dias normais.




Figura 19: Impacto de tipos de dia no fluxo por terminal

O gráfico apresentado evidencia que os feriados correspondem aos períodos com maior redução relativa da mobilidade, particularmente nas primeiras horas da manhã, coincidindo com o período de ponta. Este efeito é mais acentuado nos terminais de Campo Grande, Oriente e Sete Rios, onde se observam quebras significativas, refletindo a forte dependência destes locais de deslocações pendulares associadas a atividades laborais e escolares.

As vésperas de feriado apresentam, de forma geral, variações mais moderadas, com ligeiras reduções durante a manhã e alguns aumentos no período da tarde e noite, sugerindo uma possível antecipação de deslocações ou maior peso de atividades de lazer.

Já os dias pós-feriado, tendem a aproximar-se dos padrões de dias normais, evidenciando apenas pequenas oscilações ao longo do dia, o que indica um rápido restabelecimento da dinâmica habitual de mobilidade.

Os períodos de ponte apresentam um comportamento intermédio, com reduções relevantes, embora menos acentuadas do que nos feriados,

Em particular, o terminal de Cais do Sodré distingue-se dos restantes por apresentar variações menos expressivas e, em alguns períodos, até aumentos relativos face aos dias normais, sugerindo uma menor dependência de deslocações pendulares e uma maior associação a atividades de lazer e turismo.

Em síntese, os resultados confirmam que os efeitos de calendário influenciam de forma significativa os padrões de mobilidade, sendo esse impacto mais pronunciado nos terminais com maior componente pendular, como o Campo Grande.




Figura 20: Fluxo por hora — diferentes tipos de dias

Complementando a análise anterior baseada na variação percentual, este gráfico apresenta os valores absolutos do fluxo médio de dispositivos ao longo do dia para os diferentes tipos de dias, permitindo uma leitura mais direta da magnitude das diferenças observadas.

De forma geral, confirma-se que os feriados (linha azul tracejada) correspondem a níveis de mobilidade significativamente inferiores aos dias normais, sobretudo durante o período da manhã, evidenciando a redução das deslocações pendulares. Este efeito é particularmente visível nos terminais de Campo Grande, Oriente e Sete Rios, onde a diferença entre dias normais e feriados é mais acentuada.

As vésperas de feriado e os períodos de ponte apresentam, em vários casos, valores iguais ou superiores aos dias normais durante a tarde e início da noite, sugerindo um aumento de mobilidade associado a atividades de lazer ou deslocações antecipadas. Por outro lado, os dias pós-feriado tendem a aproximar-se dos padrões típicos, com diferenças pouco expressivas ao longo do dia.

O terminal do Cais do Sodré apresenta novamente um comportamento distinto, com diferenças mais reduzidas entre os diferentes tipos de dias, reforçando a sua menor dependência de mobilidade pendular.

Em geral, esta análise complementar confirma os padrões identificados anteriormente, evidenciando então a influência dos efeitos de calendário tanto na intensidade como na distribuição temporal da mobilidade.

5.2 Eventos Desportivos

Para além dos padrões regulares de mobilidade urbana, eventos de grande dimensão, como os jogos de futebol realizados na cidade, podem gerar alterações significativas nos fluxos de passageiros nos terminais de transporte. Nesta secção analisa-se o impacto destes eventos na mobilidade observada.

Impacto dos eventos desportivos por terminal

A análise do impacto dos jogos ao nível de cada terminal (Figura 30) revela que o aumento da mobilidade não é uniforme entre os diferentes locais. Embora todos os terminais apresentem um aumento no número médio de passageiros durante períodos associados a jogos, a magnitude desse efeito varia de forma significativa.

Neste contexto, o impacto foi calculado como a variação percentual entre a mobilidade média observada em períodos com jogos e a mobilidade média em períodos sem jogos, considerando a variável *C1* como indicador principal de mobilidade. Desta forma, o impacto representa o aumento relativo da mobilidade associado à ocorrência de eventos desportivos em cada terminal.

Esta medida permite comparar terminais com diferentes níveis base de mobilidade, evidenciando não apenas onde existem mais passageiros em termos absolutos, mas sobretudo onde a realização de jogos provoca uma alteração proporcional mais significativa nos padrões de mobilidade.




Figura 21: Aumento percentual da mobilidade média (*C1*) por terminal durante períodos associados a jogos

O terminal do Campo Grande destaca-se como o mais afetado, registando um aumento de aproximadamente 100% na mobilidade, praticamente duplicando o número médio de passageiros em períodos de jogo. Nos restantes terminais o impacto é mais moderado, com aumentos entre cerca de 7% e 23%.

Impacto da localização dos eventos desportivos na mobilidade por terminal

De forma a compreender melhor a influência dos eventos desportivos na mobilidade das interfaces analisadas, foi também realizada uma análise diferenciando os jogos realizados nos dois principais estádios da cidade — o Estádio da Luz e o Estádio José Alvalade — e o respetivo impacto nos terminais.

Os resultados indicam que os jogos realizados no Estádio da Luz tendem a gerar, em média, um maior número absoluto de passageiros em cada terminal analisado, à exceção do terminal do Campo Grande. Este comportamento pode estar relacionado com a maior capacidade do estádio e com a maior atratividade dos eventos ali realizados, o que se traduz num aumento mais generalizado dos fluxos de mobilidade na rede de transportes de Lisboa.




Figura 22: Mobilidade média (C1) por terminal em períodos sem jogo e durante jogos no Estádio da Luz e no Estádio de Alvalade

No entanto, quando se analisa o impacto relativo dos jogos em cada terminal, observa-se um comportamento distinto. Em particular, os jogos realizados no Estádio José Alvalade apresentam o maior impacto proporcional no terminal do Campo Grande. Neste caso, verifica-se um aumento de aproximadamente 202% na mobilidade média durante períodos associados a jogos, evidenciando uma forte dependência deste terminal para o acesso ao estádio. Neste terminal, durante os jogos realizados no Estádio de Alvalade, o número de passageiros triplica face a um dia "normal" sem a ocorrência destes jogos.




Figura 23: Aumento percentual dos eventos desportivos na mobilidade (C1) por terminal e estádio, comparando os períodos de jogos no Estádio da Luz e no Estádio José Alvalade

Este resultado sugere que, embora os jogos no Estádio da Luz gerem volumes absolutos mais elevados de passageiros, os jogos em Alvalade provocam variações relativas mais acentuadas na mobilidade do terminal mais próximo - o do Campo Grande - refletindo a forte ligação entre este terminal e o Estádio José Alvalade.

Perfil temporal da mobilidade (C1) média por terminal e estádio

A Figura 33 apresenta a evolução do número médio de passageiros ao longo do dia, distinguindo períodos sem jogo e períodos com jogos realizados no Estádio da Luz e no Estádio de Alvalade.

Perfil temporal da mobilidade por terminal e localização do jogo




Figura 24: Evolução do número médio de passageiros ao longo do dia, distinguindo períodos sem jogos e períodos com jogos realizados no Estádio da Luz e de Alvalade

Observa-se novamente um impacto particularmente significativo dos jogos realizados em Alvalade no terminal do Campo Grande. A linha correspondente aos jogos em Alvalade (linha verde) encontra-se consistentemente acima da média observada em dias sem jogo (linha azul), evidenciando um aumento substancial da mobilidade neste terminal.

Destacam-se quatro picos relevantes na mobilidade ao longo do período analisado. O primeiro ocorre por volta das 17 horas, associado à chegada de passageiros para aqueles jogos que se iniciam aproximadamente às 18 horas. O segundo pico verifica-se às 19 horas, refletindo a chegada de passageiros para jogos com início por volta das 20 horas. O terceiro pico surge às 20 horas e está relacionado com a saída de espectadores de jogos que começaram às 18 horas. Por fim, observa-se um quarto pico às 22 horas, correspondente à saída de passageiros de jogos iniciados por volta das 20 horas.

Por outro lado, para os jogos realizados no Estádio da Luz, não se identificam picos de mobilidade significativamente superiores ao número médio de passageiros observado em dias normais. Este resultado pode ser explicado pela configuração da rede de transportes. O terminal do Campo Grande é o único que permite um acesso direto a um dos estádios (Estádio de Alvalade), conduzindo a uma maior concentração de passageiros nesse terminal em dias de jogo.

Em contraste, o acesso ao Estádio da Luz implica normalmente a utilização de outros terminais que não os analisados, o que leva a que os passageiros se distribuam pelo vários terminais em estudo, funcionando estes sobretudo como pontos de ligação para outras estações que permitem chegar ao estádio.

Impacto dos eventos desportivos ao longo do dia: dias úteis vs. fins de semana

A Figura 34 apresenta a evolução da mobilidade média ao longo do dia distinguindo entre períodos com e sem jogos, bem como entre dias úteis e fins de semana. A análise revela padrões distintos que evidenciam a forma como os eventos desportivos interagem com os fluxos naturais da cidade.




Figura 25: Evolução do número médio de passageiros ao longo do dia, distinguindo períodos sem jogos e períodos com jogos: comparação entre dias úteis e fins de semana

Durante os dias úteis, observa-se que o impacto dos jogos se manifesta sobretudo no período da tarde. Entre as 16:00 e as 18:00, a mobilidade associada a dias com jogo aumenta de forma significativamente mais acentuada do que a tendência observada em dias sem jogo. Em particular, pelas 18:00, o número médio de passageiros em dias com jogo ultrapassa o valor máximo (médio) observado num dia normal. Este comportamento sugere que os eventos desportivos intensificam o pico de mobilidade da tarde, resultando numa sobreposição entre dois fluxos distintos: o deslocamento de adeptos em direção ao estádio e o fluxo habitual de trabalhadores no regresso a casa. Como consequência, o sistema de transportes tende a atingir níveis de pressão particularmente elevados neste intervalo temporal.

Nos fins de semana, o padrão observado é substancialmente diferente. A partir das 16:00, a mobilidade em dias com jogo afasta-se claramente da tendência habitual (dias sem jogo), mantendo-se consistentemente superior até ao final do dia. Neste contexto, os jogos não representam apenas um acréscimo de passageiros, mas tornam-se o principal fator da dinâmica de mobilidade urbana. Verifica-se ainda que o pico de mobilidade é deslocado para cerca das 19:00, enquanto num fim de semana sem jogo a atividade tenderia a estabilizar ou a diminuir progressivamente a partir do final da tarde.

Adicionalmente, observa-se que, após o pico associado ao jogo, a mobilidade permanece relativamente elevada durante as horas seguintes, particularmente entre as 20:00 e as 22:00, o que poderá refletir o fluxo de saída dos adeptos após o término do evento e o prolongamento de atividades de lazer nas áreas envolventes.

5.3 Condições Meteorológicas

Para além dos eventos pontuais como os jogos de futebol, fatores ambientais externos podem também influenciar significativamente os padrões de mobilidade urbana. Entre estes, as condições meteorológicas — em particular a ocorrência de precipitação e de temperaturas extremas — constituem um elemento relevante na forma como os utilizadores planeiam e realizam as suas deslocações.

Impacto da ocorrência de precipitação em cada terminal

A ocorrência de chuva tende, em geral, a alterar os níveis de mobilidade nos terminais analisados, verificando-se tanto reduções como aumentos dependendo da interface considerada.

A Figura 35 apresenta o impacto percentual da ocorrência de chuva na mobilidade média ($C1$) em cada terminal. Verifica-se que a ocorrência de chuva tende, em geral, a alterar os níveis de mobilidade nos terminais analisados, verificando-se tanto reduções como aumentos dependendo da interface considerada. O terminal do Cais do Sodré apresenta a maior redução de mobilidade (-10.8%), seguido do Oriente (-0.4%) e do Campo Grande (-0.1%). De notar que, para estes dois últimos terminais (Oriente e Campo Grande), o efeito da ocorrência de precipitação, quando não considerada a sua intensidade, é praticamente irrelevante. Mais à

frente, veremos que, quando considerada a intensidade da chuva, o efeito não é bem assim. Em contraste, o terminal de Sete Rios apresenta o efeito contrário com um ligeiro aumento da mobilidade durante períodos de chuva (+2.7%). Estes resultados sugerem que a sensibilidade às condições meteorológicas não é uniforme entre os terminais, podendo refletir diferenças na localização, acessibilidade ou perfil dos utilizadores.




Figura 26: Impacto percentual da ocorrência de chuva na mobilidade (C1) de cada terminal

Impacto da intensidade da precipitação em cada terminal

No entanto, quando se considera a intensidade da precipitação (fraca, moderada ou forte), verifica-se que o seu efeito não é uniforme entre os terminais. Enquanto no terminal do Cais do Sodré o aumento da intensidade da chuva está associado a uma redução progressiva da mobilidade, nos restantes terminais — particularmente em Sete Rios e Oriente — a ocorrência de chuva forte origina níveis de mobilidade superiores aos observados em períodos sem chuva ou com precipitação fraca.




Figura 27: Efeito da intensidade da chuva na mobilidade (C1) de cada terminal

Este comportamento poderá estar relacionado com a existência de melhores infraestruturas de abrigo e acessibilidade nestes terminais, tornando-os mais atrativos durante condições meteorológicas adversas. Adicionalmente, a chuva forte poderá incentivar uma transferência do modo de transporte: pedonal ou automóvel para os transportes públicos, conduzindo a um aumento do número de passageiros nestas interfaces de maior capacidade e conectividade.

Distribuição temporal do impacto da intensidade da precipitação

A análise da mobilidade média ao longo do dia em função da intensidade da precipitação (Figura 37) evidencia que a chuva não afeta apenas o volume de deslocações, mas também a sua distribuição temporal.




Figura 28: Impacto temporal da intensidade da precipitação na mobilidade urbana (C1) em cada um dos terminais

O terminal do Oriente destaca-se novamente pelos valores absolutos de mobilidade significativamente superiores aos restantes terminais, independentemente das condições meteorológicas. Observa-se, contudo, que em contextos de chuva forte ocorre uma intensificação adicional da procura durante o período da tarde, particularmente entre as 14h e as 18h, onde os valores ultrapassam os 1.800 dispositivos. Este comportamento sugere que, apesar da elevada estabilidade do terminal, condições meteorológicas adversas podem levar a uma maior concentração das deslocações, sobretudo em períodos de regresso a casa.

No Campo Grande, o impacto da precipitação revela um padrão particularmente interessante. Em situações de chuva forte, verifica-se uma antecipação clara da mobilidade da tarde, com um aumento expressivo logo às 7h e novamente entre as 15h e as 18h. Este comportamento parece refletir a forte componente pendular e académica associada ao terminal, sugerindo que os utilizadores tendem a antecipar deslocações em resposta a condições meteorológicas adversas. Após o pico da tarde, observa-se uma quebra acentuada da mobilidade, indicando uma redução das deslocações não essenciais.

O terminal do Cais do Sodré apresenta um comportamento distinto dos restantes interfaces. Em condições de chuva fraca e moderada, os padrões mantêm-se relativamente próximos dos observados em períodos sem precipitação. Contudo, em cenários de chuva forte, verifica-se uma redução significativa da mobilidade durante parte da tarde e da noite, especialmente após as 19h. Este resultado está em conformidade com os resultados do gráfico anterior, que já apontavam para um declínio da mobilidade neste terminal com o agravamento da intensidade da precipitação. Isto poderá estar associado à forte componente de lazer, restauração e vida noturna da envolvente do terminal, tornando a procura mais sensível às condições climáticas adversas.

Por sua vez, o terminal de Sete Rios revela um comportamento intermédio, mantendo uma estrutura temporal relativamente estável entre os diferentes níveis de precipitação. Ainda assim, em situações de chuva moderada e forte observa-se um aumento da mobilidade durante a manhã e o período da tarde, particularmente entre as

9h e as 17h. Este padrão poderá refletir a função do terminal enquanto interface regional e de longo curso, onde as deslocações tendem a ser menos adiáveis mesmo em condições meteorológicas desfavoráveis.

De notar que em situações de chuva forte, após o período de maior intensidade de mobilidade, observa-se também uma queda acentuada na procura. Por exemplo, às 19h, o número médio de dispositivos é significativamente inferior aos valores médios em dias sem precipitação ou precipitação mais fraca. Este comportamento sugere que, após a realização das deslocações essenciais — sobretudo relacionadas com o regresso a casa — as viagens não obrigatórias tendem a ser reduzidas ou canceladas, levando a uma desaceleração mais rápida da atividade urbana.

De forma global, os resultados sugerem que a precipitação influencia não apenas o volume de mobilidade, mas sobretudo a sua distribuição temporal, conduzindo em vários casos a fenómenos de concentração e antecipação das deslocações. Observa-se igualmente que a sensibilidade à chuva varia consoante a função urbana de cada terminal, distinguindo-se interfaces mais associados a mobilidade obrigatória daqueles com maior componente de lazer e atividades opcionais.

Impacto da intensidade da precipitação ao longo do dia: dias úteis vs. fins de semana

Ao analisar a mobilidade média por hora distinguindo dias úteis e fins de semana, verifica-se que o impacto da precipitação varia significativamente consoante o contexto semanal.




Figura 29: Impacto da intensidade da precipitação na mobilidade (C1): comparação entre dias úteis e fins de semana

Dias úteis

Nos dias úteis, a mobilidade apresenta um padrão relativamente consistente ao longo das diferentes intensidades de chuva, mantendo-se níveis elevados durante os períodos de maior atividade urbana. Inclusive, em vários momentos do dia, a mobilidade associada a chuva forte encontra-se acima dos restantes níveis de precipitação.

Este comportamento indica que, em contexto laboral, as condições meteorológicas adversas não impedem as deslocações obrigatórias, podendo até contribuir para uma maior concentração de passageiros nos terminais. A necessidade de deslocação para atividades profissionais ou escolares leva os utilizadores a recorrer aos transportes, aumentando a densidade de mobilidade durante os períodos de maior precipitação.

Fins de semana

Em contraste, durante os fins de semana, a precipitação apresenta um efeito diferente. A partir do período da tarde, observa-se uma tendência de redução da mobilidade em contextos de chuva, especialmente quando a intensidade é mais elevada.

Este padrão sugere que, na ausência de obrigações profissionais, muitos utilizadores optam por cancelar ou adiar deslocações não essenciais, como atividades de lazer ou compras, conduzindo a uma diminuição global da mobilidade.

Impacto da temperatura na mobilidade em cada terminal

A análise da correlação entre a afluência aos interfaces de transporte e as variáveis térmicas revela padrões distintos de comportamento urbano em Lisboa.




Figura 30: Impacto da temperatura na mobilidade (C1) média em cada terminal

O interface do Oriente destaca-se pela sua elevada elasticidade térmica, apresentando um crescimento praticamente linear da mobilidade à medida que a temperatura aumenta, ultrapassando os 1.500 dispositivos detetados nos dias com temperaturas superiores a 30°C. Este comportamento sugere que a procura neste terminal é particularmente sensível às variações térmicas. Uma possível explicação para este fenómeno poderá estar associada a fluxos de lazer e turismo, cuja intensidade tende a aumentar em períodos de temperaturas mais elevadas. De facto, o período de verão — altura em que se registam as temperaturas mais elevadas na cidade de Lisboa — coincide também com a época onde existem mais turistas, o que se pode refletir num aumento da utilização dos transportes públicos. Adicionalmente, a proximidade deste terminal ao Aeroporto Humberto Delgado constitui um fator potencialmente relevante que contribui para níveis mais elevados de mobilidade.

Em contraste, os interfaces do Campo Grande e do Cais do Sodré apresentam um comportamento mais estável face às variações de temperatura. A mobilidade nestes terminais aumenta gradualmente até cerca dos 20°C, mas a partir desse ponto tende a estabilizar, sem alterações significativas mesmo quando a temperatura continua a subir. Este padrão sugere que a procura nestes locais está sobretudo associada a deslocações regulares do quotidiano, menos sensíveis às condições meteorológicas. No caso específico do Campo Grande, a reduzida variação poderá estar relacionada com uma predominância de movimentos pendulares obrigatórios, de natureza profissional ou académica, que são indiferentes às oscilações climáticas. Ainda assim, tanto o Campo Grande como o Cais do Sodré evidenciam uma ligeira redução da mobilidade em situações de calor extremo (temperaturas superiores a 30°C). Neste último, este comportamento poderá estar associado à forte componente de deslocações de natureza profissional e académica. Durante os períodos de temperaturas mais elevadas — que coincidem tipicamente com os meses de verão — verifica-se também o período de férias escolares. Estes fatores contribuem para uma diminuição das deslocações diárias associadas ao estudo, refletindo-se numa redução da mobilidade observada nesta interface.

Por último, o interface de Sete Rios mantém uma progressão relativamente constante à medida que a temperatura aumenta. Este comportamento pode estar relacionado com o papel deste terminal enquanto ponto de ligação para transportes regionais e de longo curso. Nestas interfaces, a procura tende a aumentar gradualmente em períodos de maior atividade na cidade e durante épocas mais quentes do ano, mas de forma relativamente estável, sem as variações mais acentuadas que se observam em zonas com maior componente turística.

5.4 Congestionamento Rodoviário (Waze)

Esta secção analisa o congestionamento rodoviário nas vias em torno dos quatro terminais, com base em dados da plataforma Waze. Conforme referido anteriormente, os registos foram filtrados para uma distância de 500 metros em torno da área de cada terminal.

O indicador principal é o **LEVEL** do Waze, uma escala de 0 a 5 que representa o grau de congestionamento da via: LEVEL=0 corresponde a $\geq 80\%$ da velocidade de tráfego livre, LEVEL=1 (61–80%), LEVEL=2 (41–60%), LEVEL=3 (21–40%), LEVEL=4 (1–20%) e LEVEL=5 à via bloqueada. Duas variáveis complementam a análise: o **DELAY**, que mede em segundos o atraso de cada segmento de via face ao tempo de percurso em condições de fluxo livre, e a **SPEED**, que regista a velocidade média de circulação em m/s no momento do *jam*.

Começamos pela análise do LEVEL nos terminais, para os dias úteis e fins de semana. Esta análise revela um problema estrutural nos dados que, como se mostra de seguida, não é exclusivo dos terminais, mas sim um problema geral da fonte de dados. A secção seguinte explora as variáveis DELAY e SPEED: ambas apresentam coerência interna com o LEVEL — maior congestionamento implica maior atraso e menor velocidade —, mas a sua análise temporal acaba por ser condicionada pelo mesmo problema estrutural identificado no LEVEL.

Distribuição Global do LEVEL — Dados dos Terminais

Antes de analisar a variação horária do congestionamento, importa observar a distribuição global do indicador LEVEL nos dados filtrados em torno dos quatro terminais. A Figura seguinte apresenta, para cada terminal, a contagem absoluta dos registos filtrados por nível.




Figura 31: Distribuição do nível de congestionamento (LEVEL 0–5) para os dados filtrados em torno dos quatro terminais intermodais.

Dois factos saltam imediatamente à vista. O primeiro é que o LEVEL=5 — via bloqueada — é o nível mais frequente em todos os terminais, com uma vantagem absoluta sobre qualquer outro nível. O segundo é que o LEVEL=0 — trânsito livre — não tem qualquer registo em nenhum dos terminais. Os registos de LEVEL=1 são também residuais em todos os terminais.

Distribuição do LEVEL nos Terminais — Dias Úteis

A figura seguinte apresenta a composição horária do LEVEL nos dias úteis para cada um dos quatro terminais, com base nos registos Waze filtrados. Cada barra representa uma hora do dia, dividida proporcionalmente pelos diferentes níveis de congestionamento. A linha tracejada no eixo secundário indica o número total de registos por hora.




Figura 32: Distribuição percentual de LEVEL por hora do dia, dias úteis, vias em torno dos quatro terminais intermodais. A linha tracejada indica o número total de registos (eixo direito).

A observação mais imediata é que o LEVEL=5 — via bloqueada — é o nível absolutamente dominante em todos os terminais em todas as horas da noite e madrugada. No período entre as 00h e as 06h — quando as vias em torno dos terminais estão, por qualquer critério realista, com tráfego mínimo ou nulo — o LEVEL=5 aproxima-se de 100% em todos os terminais. Se este nível medisse congestionamento genuíno, deveria ser raro ou inexistente neste período.

Simultaneamente, os níveis LEVEL=0 e LEVEL=1 são praticamente inexistentes quando deveriam ser os mais comuns nestas horas. Aliás, os registos de nível 1 aparecem apenas, em quantidades visivelmente significativas, das 06h às 20h. A ausência de LEVEL=0 e LEVEL=1 de madrugada, combinada com a dominância absoluta de LEVEL=5 nesse mesmo período, não remove apenas a credibilidade ao nível 5 — remove a credibilidade interpretável a todos os níveis do indicador: se os níveis mais baixos não aparecem quando deveriam aparecer, não é possível confiar na sua presença quando aparecem.

Distribuição do LEVEL nos Terminais — Fins de Semana




Figura 33: Distribuição percentual de LEVEL por hora do dia, fins de semana, vias em torno dos quatro terminais intermodais.

O comportamento é consistente com o observado nos dias úteis, com agravamento do problema estrutural identificado.

O Problema é Geral: Qualidade dos Dados Waze Disponibilizados

Os padrões observados nas secções anteriores não são exclusivos das vias em torno dos terminais. As figuras seguintes apresentam a distribuição global do LEVEL para o conjunto dos dados brutos da cidade de Lisboa, abrangendo todos os anos disponibilizados.




Figura 34: Distribuição global do nível de congestionamento (LEVEL 0-5) por ano, dados brutos de toda a cidade. As barras indicam a contagem absoluta e os rótulos a percentagem do total de cada ano.




Figura 35: Distribuição percentual do LEVEL por hora do dia, dias úteis, dados brutos da cidade de Lisboa. Anos 2023, 2024 e 2025.




Figura 36: Distribuição percentual do LEVEL por hora do dia, fins de semana, dados brutos da cidade de Lisboa. Anos 2023, 2024 e 2025.

Estes gráficos confirmam que o problema identificado nos terminais é um problema estrutural da fonte de dados e não uma particularidade das vias analisadas.

Uma Janela de Análise Condicionada: Delay

Face às limitações documentadas, a análise do indicador LEVEL não permite, por si só, caracterizar o congestionamento real nas vias em torno dos terminais. No entanto, existe uma possibilidade de análise residual, sujeita a uma condição que não é possível garantir com estes dados: *se os registos classificados com LEVEL=1 a LEVEL=4 capturam situações de tráfego genuinamente ativo para os períodos de hora de ponta*, então os dados de DELAY associados a esses registos podem constituir um sinal com alguma validade.

O indicador de DELAY mede em segundos o atraso de cada segmento de via face ao tempo de percurso em condições de fluxo livre.




Figura 37: Mediana do delay por nível de congestionamento e terminal intermodal (LEVEL 1–5). Valores em segundos.

A figura anterior mostra a mediana do delay para os níveis de congestionamento 1 a 5, desagregada por terminal. Os registos de LEVEL=5 possuem o valor mediano -1 , que corresponde ao valor padrão indicado na descrição dos dados para via bloqueada, confirmando-se que a totalidade dos registos de LEVEL=5 assume este valor.




Figura 38: Composição da variável DELAY nos registos de LEVEL=5, por terminal intermodal.

Para os restantes níveis, o padrão é consistente e gradual: à medida que o nível de congestionamento aumenta, o delay mediano aumenta também, confirmando a coerência da variável DELAY com o comportamento esperado — *jams* mais severos traduzem-se efetivamente em maiores tempos de atraso.




Figura 39: Mediana do delay (segundos) por hora do dia, dias úteis vs. fins de semana, para cada terminal. Filtro: LEVEL=1 a 4, delay > 0.

Se a condição referida anteriormente for válida, o padrão é o esperado: nos dias úteis, o delay apresenta dois picos coincidentes com as horas de ponta da manhã e da tarde. Nos fins de semana, o perfil é mais plano, sem picos matinais pronunciados (excepto no Oriente, talvez devido ao seu contexto urbano comercial e cultural envolvente), e com valores globalmente inferiores. Esta diferença entre dias úteis e fins de semana é coerente com o padrão de mobilidade urbana conhecido.

Uma conclusão que se pode retirar é que estes níveis de atraso nas horas de ponta dos dias úteis afetam diretamente a pontualidade dos operadores rodoviários com serviços programados que utilizam as vias em torno destes terminais, contribuindo igualmente para maiores períodos de permanência verificados na afluência de pessoas nos terminais.

Velocidade (SPEED) nas Vias dos Terminais

A variável SPEED representa a velocidade média de circulação, em metros por segundo, no segmento de via onde o evento foi registado.




Figura 40: Velocidade mediana (m/s) por nível de congestionamento e terminal intermodal (LEVEL 1–5).

Coerência com o Nível de Congestionamento A análise da velocidade mediana por nível de congestionamento revela um padrão coerente: à medida que o LEVEL aumenta de 1 para 4, a velocidade mediana diminui de forma consistente em todos os terminais, confirmando a validade interna da variável SPEED. Nota-se, no entanto, que os terminais Oriente e Sete Rios apresentam alguma inconsistência na passagem do nível 1 para o nível 2, onde não se verifica uma diminuição clara. Os registos de nível 5 possuem velocidade mediana zero, coerente com a definição de via bloqueada e também confirmada:




Figura 41: Composição da variável SPEED nos registos de LEVEL=5, por terminal intermodal.

Anomalia nos Padrões Horários Quando se analisa a evolução da velocidade mediana ao longo do dia, emerge uma contradição: as velocidades medianas são mais elevadas precisamente nas horas de ponta da manhã e da tarde, quando seria de esperar o oposto. Este padrão contradiz diretamente os resultados do indicador DELAY, onde as horas de ponta coincidem com os maiores tempos de atraso.

A explicação reside no mesmo problema de distribuição já identificado para o LEVEL. Os níveis mais baixos — LEVEL=1 e LEVEL=2, associados a velocidades mais elevadas — estão praticamente ausentes nas horas noturnas e surgem concentrados nas horas de ponta, elevando artificialmente a velocidade mediana nesses períodos. Nas horas noturnas, a dominância do LEVEL=5 (velocidade zero) resulta paradoxalmente em velocidades medianas mais baixas. Inferimos por isso que, se a distribuição fosse coerente com a realidade urbana, os picos de velocidade nas horas de ponta seriam, na verdade, vales nos gráficos.




Figura 42: Velocidade mediana (m/s) por hora do dia, dias úteis vs. fins de semana, para cada terminal. Filtro: LEVEL=1 a 4.

Figuras Complementares — Heatmaps por Nível de Congestionamento

Os gráficos seguintes apresentam os *heatmaps* de intensidade horária para cada nível de congestionamento (LEVEL=5 a LEVEL=1), separando dias úteis de fins de semana. As limitações de qualidade dos dados documentadas nas secções anteriores aplicam-se igualmente a todas estas figuras.




Figura 43: Heatmap de LEVEL=5 (via bloqueada) por hora do dia e dia da semana. Dominância absoluta em todas as horas, incluindo madrugada — padrão inconsistente com a realidade urbana.




Figura 44: Heatmap de LEVEL=4 (congestionamento grave, 1–20% da velocidade livre) por hora do dia e dia da semana.




Figura 45: Heatmap de LEVEL=3 (congestionamento moderado, 21–40% da velocidade livre) por hora do dia e dia da semana. Padrão de hora de ponta visível em Oriente, Campo Grande e Sete Rios, com redução marcada ao fim de semana.




Figura 46: Heatmap de LEVEL=2 (trânsito lento, 41–60% da velocidade livre) por hora do dia e dia da semana. Padrão de hora de ponta presente mas mais difuso.




Figura 47: Heatmap de LEVEL=1 (trânsito ligeiro, 61–80% da velocidade livre) por hora do dia e dia da semana. Registos muito escassos, concentrados na banda das 07h–09h de dias úteis.

Conclusões

A análise dos dados Waze para os quatro terminais intermodais de Lisboa não permite retirar conclusões robustas sobre o congestionamento rodoviário nas vias envolventes. A razão é de natureza estrutural: o indicador LEVEL apresenta uma distribuição inconsistente com a realidade urbana, dominada pelo LEVEL=5 nas horas de menor tráfego, o que compromete a interpretação de todos os níveis. Para ser possível caracterizar o congestionamento de forma fiável, seria necessário dispor de dados com uma distribuição de LEVEL credível.

A única conclusão operacionalmente sustentável é obtida através do indicador DELAY, com a reserva já descrita: nas horas de ponta dos dias úteis, os atrasos nas vias em torno dos terminais são significativamente superiores, com impacto direto na pontualidade dos operadores rodoviários que utilizam esses corredores.

5.5 Oferta de Transporte Público e Alinhamento com a Afluência (GTFS)

Esta secção apresenta a análise da oferta de transporte público programada nos quatro terminais intermodais, com base nos dados GTFS e *web scraping* descritos no Conjunto 6 de Data Understanding. São caracterizados o perfil de oferta de cada terminal (operadores, rotas, viagens) e o seu alinhamento com a afluência observada (variável C1 da Vodafone).

Perfil da Oferta por Terminal

Número de Paragens/Estações por Interface

A tabela seguinte resume o número de paragens/estações/plataformas encontradas por interface e operador dentro do raio de 300 m.

Interface	Metro	CP	Fertagus	Carris	Carris Met.	TransTejo	FlixBus	R. Expressos	Total
Cais do Sodré	2*	1	—	19	4	1	—	—	27
Oriente	2*	1	—	9	12	—	1	1	26
Campo Grande	4**	—	—	10	24	—	—	—	38
Sete Rios	2*	1	1	17	6	—	1	1	29

** Campo Grande é estação de correspondência Amarela/Verde — o GTFS modela explicitamente 4 plataformas (CG1–CG4): 2 linhas × 2 sentidos cada.

* Cais do Sodré (Linha Verde), Oriente (Linha Vermelha) e Sete Rios (Linha Azul) são estações de linha simples: o GTFS publica um único *stop_id* por estação, mas cada uma serve 2 sentidos de circulação, contabilizando-se 2 plataformas funcionais por estação.

Campo Grande é o terminal com menos operadores, ainda que contenha o maior número de paragens, graças à forte presença da Carris Metropolitana. Cais do Sodré destaca-se pela exclusividade no transporte fluvial e pela presença mais forte da Carris. Oriente e Sete Rios são os terminais com maior número de operadores e, por serem os únicos com presença da FlixBus e da Rede Expressos, têm uma abrangência territorial muito mais ampla nos destinos que possibilitam.

Volume, Diversidade e Intensidade de Serviço

O gráfico seguinte compara os quatro terminais segundo três dimensões: o número de operadores presentes (intermodalidade), o total de rotas distintas e a intensidade de serviço medida pelo número de viagens distintas programadas.




Figura 48: Perfil da oferta nos terminais intermodais: nº de operadores, rotas e viagens distintas. Valores normalizados (*máx* = 1); valor absoluto anotado sobre cada barra.

O Cais do Sodré, embora tenha apenas 33 rotas, possui uma intensidade de serviço praticamente tão elevada quanto Sete Rios — que é o terminal com mais rotas. Isso explica-se pelo facto de as rotas da Rede Expressos em Sete Rios terem intervalos de partida muito mais alargados. O mesmo raciocínio se aplica ao Campo Grande: apesar das 36 rotas, tem uma intensidade de serviço considerável graças às duas linhas de metro e à

forte presença da Carris. O Oriente destaca-se por ter o segundo maior número de rotas e, simultaneamente, a maior intensidade de serviço.

Para facilitar a leitura destas relações, foi criado um diagrama de bolhas que cruza simultaneamente as três dimensões:




Figura 49: Posicionamento relativo dos terminais: rotas vs. viagens, com tamanho da bolha proporcional ao número de operadores.

O Oriente ocupa um posicionamento claramente dominante no eixo das viagens distintas, combinando oferta densa de transportes urbanos com serviços de longa distância. O Sete Rios destaca-se no eixo das rotas, mas não em intensidade equivalente de viagens — pois o elevado número de rotas da Rede Expressos tem, por definição, frequências mais baixas que o transporte urbano.

Associação entre Intensidade de Serviço e Afluência C1

Verifica-se uma associação positiva visível entre a oferta de transportes (intensidade de serviço dada pelo número de viagens distintas) e a afluência estimada pela variável C1. Esta relação sugere que os terminais com maior intensidade de serviço são também os que concentram maior afluência — uma relação esperada, mas que reforça a adequação da C1 como *proxy* de procura e a correta captação da realidade da mobilidade nos dados GTFS e *web scraping*.




Figura 50: Associação entre intensidade de serviço (n^o de viagens distintas GTFS) e afluência média C1 por terminal.

Verifica-se o mesmo padrão nos dois casos: o Oriente é o terminal com maior n^o de viagens distintas e é também o que apresenta maior amplitude na distribuição da variável C1, seguido do Sete Rios, do Cais do Sodré e do Campo Grande.

Oferta por Operador e Terminal

O gráfico seguinte desagrega a oferta de rotas por terminal e por operador, permitindo identificar os operadores dominantes em cada interface.




Figura 51: Número de rotas por terminal e operador (raio 300 m).

A Rede Expressos é o operador dominante em Sete Rios (346 rotas) e tem também presença relevante no Oriente (141 rotas), confirmando o papel destes terminais como pontos de entrada/saída rodoviária de longa distância. A Carris demonstra oferta substancial no Cais do Sodré e Campo Grande, enquanto a Carris Metropolitana tem maior presença em Campo Grande. A CP concentra-se no Oriente e Sete Rios; o FlixBus está quase inteiramente centrado no Oriente (55 rotas), que é também um forte ponto de entrada de autocarros internacionais em Lisboa. A TransTejo serve exclusivamente o Cais do Sodré (6 rotas de *ferry*) e o Fertagus aparece apenas em Sete Rios (1 rota ferroviária para a Margem Sul).

Comparação entre Regimes Operacionais

O gráfico seguinte compara os quatro regimes operacionais (Dia Útil, Sábado, Domingo e Feriado) em período letivo, usando dias de referência para cada terminal, somando todos os operadores.




Figura 52: Frequência horária por regime e terminal (período letivo). Partidas únicas por hora, soma de todos os operadores.

Em todos os terminais é evidente a supremacia do dia útil em termos de volume de partidas, reflectindo a maior procura associada aos fluxos pendulares de trabalho e escola. O Oriente e o Sete Rios destacam-se como os terminais com maior intensidade horária, atingindo picos próximos das 350 partidas por hora, o que é consistente com o maior número de operadores e rotas que os caracterizam.

O Cais do Sodré e o Campo Grande apresentam um perfil marcadamente bimodal no dia útil, com picos concentrados na manhã e ao fim da tarde — típico de terminais com forte componente pendular.

Nos regimes de fim de semana e feriado, a frequência horária é globalmente mais baixa e distribui-se de forma mais uniforme ao longo do dia, sem os picos matinais e vespertinos típicos do dia útil. Esta compressão do serviço é transversal a todos os terminais, sendo mais acentuada no Cais do Sodré e no Campo Grande, onde a diferença entre regimes é mais marcada.

Uma particularidade digna de nota verifica-se no terminal do Oriente, onde a frequência horária ao domingo supera a do sábado e a do feriado em vários intervalos do dia. Este comportamento poderá reflectir a concentração de serviços de longa distância — nomeadamente da Rede Expressos e da FlixBus — com partidas aos Domingos mais densas, possivelmente associadas a fluxos de regresso a outras regiões/países após o fim de semana.

Alinhamento entre Oferta Programada e Afluência

Esta secção apresenta a relação entre a oferta de transportes públicos e a afluência observada nos quatro terminais ao longo de quatro regimes operacionais: Dia Útil em período letivo, Sábado, Domingo e Feriado.

Cada gráfico combina dois eixos independentes: o eixo esquerdo (barras empilhadas por operador) representa o número de viagens GTFS partindo do terminal por hora, num raio de 300 metros; o eixo direito (linha contínua) representa a média horária da variável C1 da Vodafone. Os eixos têm escalas independentes — a linha C1 foi posicionada visualmente para permitir comparar o perfil de picos e vales, sem implicar equivalência de unidades.

A data de referência para o regime de Dia Útil é 13 de abril de 2026 (segunda-feira, período letivo). Para Sábado e Domingo usam-se 18 e 19 de abril de 2026, respetivamente. O regime de Feriado usa 10 de junho de 2026 (Dia de Portugal) para os operadores GTFS e 1 de maio de 2026 para a Rede Expressos.

Dia Útil — Período Letivo




Figura 53: Padrão de oferta vs. afluência em dia útil (período letivo).

Sábado




Figura 54: Padrão de oferta vs. afluência ao Sábado.

Domingo




Figura 55: Padrão de oferta vs. afluência ao Domingo.

Feriado




Figura 56: Padrão de oferta vs. afluência em dia de Feriado.

Em todos os regimes, observa-se uma correspondência entre a intensidade da oferta GTFS e a afluência medida pela variável C1, ainda que com amplitudes diferentes consoante o terminal e o regime. Alguns desfasamentos verificados poderão ser explicados pelo contexto urbano envolvente, que pode conduzir a períodos de maior permanência e observação de dispositivos nas quadrículas dos terminais.

Conclusões

A integração de dados GTFS e *web scraping* contribuiu para a caracterização dos terminais intermodais em estudo em diversas dimensões: número de operadores, rotas e viagens distintas. Adicionalmente, uma vez que os operadores dimensionam os seus horários e frequências com base em estudos internos de bilhética e outros dados não públicos, o GTFS funciona como um reflexo indireto da procura real esperada — conferindo ao conjunto um valor analítico que vai além da mera descrição da oferta.

A forte aderência morfológica verificada entre as curvas de oferta GTFS e a afluência C1 da Vodafone valida a utilização dos dados de rede móvel como um *proxy* fidedigno para a procura, confirmando que a presença de dispositivos acompanha as tendências e picos de serviço programados.

5.6 Contexto Urbano dos Terminais (Overture Maps)

Os dados Vodafone respondem à pergunta “quando e quantas pessoas passam por cada terminal?” — mas não respondem sozinhos à pergunta “porquê?”. A análise de Pontos de Interesse (POI) com dados do Overture Maps permite construir um contexto urbano para cada terminal que ajuda a explicar diferenças de comportamento de afluência que os dados de rede móvel, por si só, não conseguem justificar. Esta análise é completamente independente das outras fontes de dados — foi construída apenas com dados geoespaciais abertos — e serve como referência estrutural para interpretar os padrões identificados nas restantes subsecções.

A fonte de dados, a metodologia de recolha e as 10 categorias de POI utilizadas encontram-se descritas no Conjunto 7 de Data Understanding.

O Índice de Atração Urbana (IAU)

O IAU quantifica a *densidade de oferta urbana documentada* em redor de cada terminal, combinando três factores: a **quantidade** de POI de cada categoria no raio de análise, a **fiabilidade dos dados** (o *confidence score* do Overture Maps, escala 0–1, usado como peso), e a **densidade** (normalização pela área do raio em km², garantindo comparabilidade directa entre terminais).

Fórmula do IAU por categoria:

$$\text{IAU}_{\text{categoria}} = \frac{N_{\text{POI}} \times \text{peso}_{\text{categoria}} \times \text{nível_de_confiança_médio}_{\text{categoria}}}{\text{área (km}^2\text{)}}$$

$$\text{IAU}_{\text{total}} = \sum_{\text{categorias}} \text{IAU}_{\text{categoria}}$$

Notas:

A área para o raio de 1000 m é $\pi \times 1^2 \approx 3,14 \text{ km}^2$.

Os pesos de categoria foram definidos como 1 para todas as categorias, tornando o sinal de atracção determinado exclusivamente pela densidade de POI e pelo nível de confiança médio, sem ponderação subjectiva.

O IAU é uma aproximação à *riqueza e diversidade de oferta urbana* num dado raio, ponderada pela qualidade dos dados disponíveis. Não mede fluxos de pessoas, receitas ou avaliações de utilizadores.

IAU Total por Terminal




Figura 57: IAU total por terminal (raio 1000 m). Fonte: Overture Maps Foundation, abril 2026.

O Cais do Sodré tem um IAU de 917 — 2,84 vezes mais do que o Oriente (323). Isto reflecte a extraordinária densidade urbana da Baixa Lisboeta, com mais de 4.100 POI num raio de 1 km. O Sete Rios e o Campo Grande têm valores mais próximos entre si (181 e 205, respectivamente).

Distribuição do IAU por Categoria




Figura 58: Distribuição do IAU por categoria e terminal (raio 1000 m)




Figura 59: Densidade absoluta de oferta urbana por categoria e terminal (raio 1000 m).

O Cais do Sodré domina absolutamente em várias categorias, reflectindo a extraordinária concentração de oferta urbana da Baixa Lisboaeta. O Oriente, logo a seguir, mostra presença significativa em várias categorias,

reflectindo os complexos empresariais e o destino comercial e turístico do Parque das Nações.

Com base nos valores de IAU apurados, é expectável que Cais do Sodré e Oriente concentrem os maiores fluxos de afluência e os períodos de permanência mais prolongados fora das horas de ponta e ao fim de semana — a densidade e diversidade de oferta urbana nestes terminais cria as condições para que os utilizadores encontrem motivos de permanência para além do simples acto de transbordo. Campo Grande e Sete Rios, com perfis de oferta mais contidos, deverão apresentar uma afluência que segue de forma mais estreita os ritmos do próprio sistema de transportes, com picos nas horas de ponta e menor permanência nos períodos intermédios.

Perfil Proporcional e Vocação Funcional de Cada Terminal

O IAU absoluto tem uma limitação conceptual importante: terminais localizados em zonas historicamente mais densas tendem a ter valores superiores em praticamente todas as categorias, simplesmente por estarem inseridos num tecido urbano mais rico. Para perceber em que categorias cada terminal se *especializa* relativamente à sua própria oferta total, calculou-se para cada terminal a proporção de cada categoria no IAU total ($p_{\text{categoria}} = \text{IAU}_{\text{categoria}} / \text{IAU}_{\text{total}}$).

Categoria IAU	Cais do Sodré	Sete Rios	Campo Grande	Oriente
● Restauração	33.0%	19.9%	14.1%	23.6%
● Bares e Vida Nocturna	10.8%	1.1%	1.2%	1.8%
● Comércio / Retalho	17.1%	11.7%	11.1%	18.7%
● Alojamento	10.6%	3.2%	0.7%	2.0%
● Saúde	1.2%	9.5%	8.1%	5.2%
● Desporto e Fitness	0.8%	3.4%	5.3%	2.5%
● Serviços do Quotidiano	10.8%	24.4%	25.5%	20.6%
● Educação	1.8%	7.1%	14.3%	2.4%
● Escritórios e Negócios	5.8%	13.1%	12.9%	18.2%
● Cultura e Entretenimento	8.0%	6.6%	6.7%	5.1%

Célula colorida = valor mais elevado por categoria (máximo por linha)

Figura 60: Perfil proporcional por terminal: proporção de cada categoria no IAU total. A azul o valor máximo de cada categoria entre os quatro terminais. Responde não a “quanto existe?” mas a “de que é feito este terminal?”.

O **Cais do Sodré** é o único terminal com um perfil forte de lazer e turismo: Restauração (33%), Bares e Vida Nocturna (10,8%) e Alojamento (10,6%) juntos representam mais de metade do IAU total (54,4%), sendo o terminal com maior foco nessas categorias. Este perfil sugere afluência resiliente em feriados e picos nocturnos e ao fim de semana que os outros terminais não apresentarão.

O **Oriente** tem o perfil mais orientado para comércio e negócios: Escritórios e Negócios (18,2%) e Comércio/Retalho (18,7%) são as duas categorias com maior peso a seguir a Restauração (23,7%) e Serviços do Quotidiano (19,9%). Este perfil é coerente com a natureza do Parque das Nações. É expectável uma queda mais acentuada ao fim de semana do que no Cais do Sodré.

O **Campo Grande** apresenta um perfil mais equilibrado e de vocação académica: Educação (14,3%) é a proporção mais elevada desta categoria em todos os terminais, completada por Serviços do Quotidiano (25,5%), Desporto e Fitness (5,3%) e Escritórios (12,9%). Este equilíbrio sugere uma afluência concentrada em horas específicas, sensível ao calendário académico e ao período laboral.

O **Sete Rios** tem também um perfil equilibrado, destacando-se por ter a maior percentagem na categoria Saúde (9,5%) entre todos os terminais.

Índice de Diversidade de Shannon

Para além do IAU, calculou-se para cada terminal o Índice de Diversidade de Shannon — uma métrica que mede “quão equilibrada” está a atracção urbana pelas diferentes categorias, permitindo uma leitura mais rápida da diversidade funcional de cada terminal.

Fórmula de Shannon:

$$H = - \sum_i p_i \cdot \ln(p_i)$$

Onde $p_i = \text{IAU}_{\text{categoria } i} / \text{IAU}_{\text{total}}$.

$H = 0$ significa concentração máxima numa só categoria;

$H = \ln(10) \approx 2,30$ significa distribuição perfeitamente uniforme pelas 10 categorias.




Figura 61: Índice de diversidade de Shannon por terminal.

O **Cais do Sodré** apresenta a maior concentração verificada (menor $H = 1,920$) — coerente com o domínio da Restauração e Lazer no seu perfil. O **Sete Rios** é o terminal com distribuição mais diversificada (maior $H = 2,049$), reflectindo uma oferta mais equilibrada pelas 10 categorias. O **Oriente** ($H = 1,925$) e o **Campo Grande** ($H = 2,041$) situam-se em posições intermédias, com o Oriente ligeiramente mais concentrado dado o peso dos Escritórios e do Comércio.

É de notar que os quatro terminais apresentam valores próximos entre si, todos próximos do máximo teórico de 2,30 — o que revela que nenhum se insere num contexto urbano monofuncional. Ainda assim, estas diferenças aparentemente marginais manifestam-se na realidade urbana em perfis e vocações funcionais significativamente distintos.

5.7 Padrões de Mobilidade de Visitantes Internacionais (Roaming)

Enquadramento e Definição da Variável

A variável C2, designada no dicionário de dados do *dataset* Vodafone Grelha como “Número de terminais em roaming na célula”, quantifica a presença de dispositivos móveis com cartões SIM estrangeiros (roaming internacional) detetados em cada célula de 200m×200m da grelha, em intervalos de 5 minutos.

Ao contrário da variável C1 — que contabiliza o total de dispositivos únicos presentes na célula, independentemente da sua origem — C2 isola especificamente os utilizadores internacionais, permitindo distinguir entre a mobilidade da população residente ou visitante doméstica e a mobilidade de turistas e viajantes provenientes do estrangeiro.

Importa salientar que C2 **não está disponível no esquema de dados de 2023**, estando presente apenas nos esquemas relativos ao período de janeiro de 2024 em diante. Esta limitação implica que a análise aqui apresentada se restringe aos anos de 2024 e 2025, o que corresponde, ainda assim, a um horizonte temporal suficientemente representativo para a identificação de padrões estruturais.

Evolução Média Horária por Terminal




Figura 62: Evolução média horária da variável C2 (terminais em roaming) por terminal intermodal, comparando dias úteis e fins de semana. Fonte: Vodafone Grelha (2024–2025).

O **Terminal de Oriente** destaca-se inequivocamente como o terminal com maior presença de dispositivos em roaming, registando valores médios de C2 substancialmente superiores aos dos restantes terminais — cerca de duas a três vezes superiores ao segundo terminal mais visitado por utilizadores internacionais (Cais do Sodré). Este resultado é diretamente explicável pela sua ligação rápida da linha vermelha do Metro que vem do Aeroporto Humberto Delgado: viajantes internacionais utilizam frequentemente o terminal de Oriente como primeiro ponto turístico, marcando assim o primeiro contacto com a rede de transportes públicos da cidade. E também pode ser explicado pela oferta internacional de autocarros de longo curso.

O **Terminal de Cais do Sodré** apresenta o segundo valor mais elevado de C2, com uma distribuição horária coerente com o seu carácter marcadamente turístico e de lazer. Uma característica distintiva é a inversão

relativa entre dias úteis e fins de semana: nos fins de semana, os valores de C2 são sistematicamente mais elevados, refletindo a intensificação da atividade turística na zona ribeirinha e a oferta de restauração e entretenimento.

Os **Terminais de Sete Rios e Campo Grande** registam valores de C2 significativamente mais baixos, o que é coerente com o seu perfil funcional. Sete Rios, apesar de ser um hub de autocarros de longa distância com ligações internacionais (FlixBus e Rede Expressos), serve essencialmente passageiros nacionais em deslocações inter-regionais. Campo Grande, por sua vez, é um terminal de mobilidade pendular e académica, orientado para os residentes da Área Metropolitana de Lisboa. Nenhum dos dois se insere no circuito turístico natural da cidade, o que explica a reduzida presença de dispositivos em roaming.

Relação com o Contexto Urbano e o IAU

Os resultados da análise de C2 apresentam forte coerência com os padrões identificados na secção anterior através do Índice de Atração Urbana (IAU): Oriente e Cais do Sodré destacaram-se como os terminais com maior densidade e diversidade de pontos de interesse, nomeadamente ao nível de alojamento, restauração, comércio e atrações culturais. A análise de C2 fornece agora uma validação empírica direta desse resultado — os terminais com maior índice de atração urbana são também os que registam maior presença de visitantes internacionais.

6 Evaluation — Conclusões

6.1 Síntese Comparativa dos Terminais

A tabela seguinte resume os principais resultados obtidos para cada terminal ao longo das diferentes dimensões de análise estudadas.

Dimensão	Cais do Sodré	Campo Grande	Sete Rios	Oriente
Contexto urbano				
Perfil funcional	Lazer, turismo e vida noturna	Académico e pendular	Hub de longa distância	Empresarial, comercial e turismo
IAU (raio 1 km)	917 (máximo)	205	181 (mínimo)	323
Índice de Shannon (diversidade POI)	1,920 (mínimo)	2,041	2,049 (máximo)	1,925
Padrões de mobilidade (Vodafone C1)				
Impacto hora de ponta (Δ C1)	$\Delta \approx -1$ (nulo)	125	99	$\Delta = 287$ (máximo)
Padrão dia útil vs fim de semana	Sem picos pendulares; FDS $\approx$ dia útil	Dois picos acentuados; forte redução FDS	Dois picos moderados; redução FDS	Dois picos pronunciados; FDS diurno elevado
Atividade noturna	Pronunciada (Sex. e FDS, após 21h)	Residual	Residual	Moderada (Parque das Nações)
Redução em férias	$\approx -17\%$ (menor)	$\approx -35\%$ pico matinal	$\approx -19\%$	$\approx -20\%$
Impacto eventos desportivos	+7% (menor)	+100% geral; +202% Alvalade	+23%	Moderado
Fatores externos				
Efeito da chuva (C1)	-10,8% (maior redução)	$\approx 0\%$	+2,7% (único aumento)	-0,4%
Sensibilidade à temperatura	Estável acima de 20°C	Estável acima de 20°C	Progressão constante	Crescimento linear até >30°C
Waze delay (horas de ponta)	Moderado	Elevado (diurno prolongado)	Moderado	Elevado
Oferta de transporte (GTFS)				
Nº de operadores GTFS	5	3 (mínimo)	7 (máximo)	6
Intensidade de oferta (GTFS)	Alta frequência	Alta (metro + Carris Met.)	Maior diversidade de rotas	Maior intensidade de viagens

6.2 Principais Conclusões

O presente estudo demonstrou ser possível caracterizar em detalhe os quatro principais terminais intermodais de Lisboa através da integração de múltiplas fontes de dados heterogéneas, cobrindo um período de dois anos e meio (janeiro de 2023 a junho de 2025). Os dados de rede móvel da Vodafone permitiram estimar a afluência e os padrões temporais de mobilidade, enquanto os dados meteorológicos do IPMA, de tráfego do Waze, de eventos desportivos, de oferta programada (GTFS) e de pontos de interesse (Overture Maps) forneceram o contexto necessário para interpretar as variações observadas. A forte aderência morfológica verificada entre as curvas de oferta GTFS e a afluência C1 da Vodafone valida a utilização dos dados de rede móvel como um *proxy* fidedigno da procura, reforçando a robustez metodológica do estudo.

Os resultados evidenciaram perfis funcionais marcadamente distintos entre os terminais. O **Oriente** destaca-se como o principal polo de mobilidade da cidade, com os fluxos mais elevados, maior sensibilidade térmica e a maior intensidade de serviço programado, refletindo uma forte componente turística, empresarial e de conectividade aeroportuária. O **Campo Grande** revela-se o terminal mais dependente de mobilidade pendular e académica: regista a maior redução de fluxo em períodos de férias (até -35% na hora de ponta matinal) e o impacto mais expressivo dos jogos em Alvalade ($+202\%$), confirmando a sua forte ligação ao Estádio José Alvalade. O **Cais do Sodré** apresenta um perfil singular, com fluxo estável ao longo do dia mas atividade noturna pronunciada às sextas-feiras e fins de semana, coerente com a extraordinária densidade de oferta de restauração e vida noturna da sua envolvente (IAU = 917). O **Sete Rios**, enquanto hub de longa distância, apresenta comportamentos intermédios com a maior diversidade de rotas e é o único terminal onde a chuva está associada a um ligeiro aumento de mobilidade ($+2,7\%$). Relativamente ao congestionamento rodoviário, os dados Waze revelaram limitações estruturais que comprometeram a análise direta, sendo o indicador de *delay* o único com leitura operacionalmente válida, confirmando o agravamento do tráfego nas horas de ponta em torno dos terminais — com implicações diretas na pontualidade dos operadores rodoviários que circulam nessas vias.

6.3 Limitações do Estudo

As principais limitações metodológicas identificadas ao longo do estudo são as seguintes:

- **Cobertura e ruído dos dados Vodafone:** os dados resultam de um algoritmo de estimação interno da Vodafone que infere a mobilidade total da população, independentemente da operadora de telecomunicações utilizada. Ainda assim, esta estimativa tem uma margem de incerteza inerente ao modelo. Adicionalmente, cada quadrícula cobre uma área geográfica mais ampla do que o perímetro físico do terminal, incorporando vias, passeios e edifícios envolventes, introduzindo ruído proveniente de dispositivos sem relação direta com a utilização do terminal.
- **Qualidade e consistência dos dados Vodafone:** o esquema dos ficheiros sofreu três alterações significativas ao longo do período de cobertura, exigindo um processo extenso de normalização. Identificaram-se lacunas temporais expressivas, sobretudo em agosto e setembro de 2024, que não correspondem a ausência real de mobilidade mas a problemas na recolha ou disponibilização dos dados.
- **Limitação dos dados Waze:** o indicador LEVEL revelou-se não fiável para análise de congestionamento real, com LEVEL=5 (via bloqueada) a representar a grande maioria dos registos em todos os terminais, incluindo nas madrugadas quando o tráfego é mínimo. Esta anomalia restringiu a análise ao indicador de *delay*, impedindo conclusões robustas sobre o impacto do congestionamento nos fluxos de mobilidade.
- **Cobertura temporal do GTFS:** os *feeds* GTFS descrevem os horários de 2024–2026, enquanto os dados observados cobrem janeiro de 2023 a junho de 2025. A análise assume que os padrões de serviço se mantiveram estáveis entre anos, o que é razoável dada a elevada estabilidade estrutural das redes de transporte de Lisboa, mas não é diretamente verificável.
- **Cobertura de operadores GTFS (Campo Grande e Oriente):** nos terminais de Campo Grande e Oriente operam outros operadores de autocarro interurbanos cujos horários não estão disponíveis em formato GTFS nem foram possíveis de obter por outros meios. A ausência destes operadores não deverá ter um impacto significativo nas métricas de rotas e viagens analisadas, uma vez que os operadores com maior volume e regularidade de serviço já se encontram representados.

- **Dados da Rede Expressos:** os horários deste operador foram obtidos por engenharia reversa da API interna do *website* oficial, constituindo uma abordagem exploratória não documentada pela operadora. Os resultados devem ser interpretados com as devidas cautelas.
- **Dados meteorológicos (IPMA):** as observações provêm de apenas três estações distribuídas por Lisboa, podendo não refletir com rigor as condições locais junto de cada terminal. Foram identificados 721 períodos horários sem registo, exigindo imputação para garantir a continuidade da série temporal.
- **Dados do Overture Maps:** os pontos de interesse correspondem a um *snapshot* estático de abril de 2026, não refletindo aberturas ou encerramentos anteriores ou posteriores a essa data.

7 Deployment — Comunicação de Resultados

Esta fase do CRISP-DM corresponde à disponibilização e comunicação dos resultados produzidos ao longo do projeto. Os entregáveis desenvolvidos pelo Grupo 15 são os seguintes:

7.1 Relatório

O presente documento constitui a entrega académica formal do projeto. Descreve de forma estruturada todas as fases do processo CRISP-DM aplicadas ao estudo dos quatro terminais intermodais de Lisboa, desde a definição dos objetivos de negócio até às conclusões obtidas e respetivas limitações.

7.2 Código

Todo o código desenvolvido ao longo do projeto foi entregue ao LxDataLab e encontra-se organizado em pastas e subpastas, podendo ser consultado e reproduzido.

7.3 Dashboard Power BI

O foco central deste projeto esteve sempre na descoberta de dados, perspetivas e analíticas que pudessem vir a ser úteis ao LxDataLab — eventualmente ao ponto de serem integradas na plataforma PGIL (*Plataforma de Gestão Inteligente de Lisboa*), que já constitui em si mesma um *dashboard* robusto e testado, pelo que não era do interesse do grupo investir esforço nessa direção.

No entanto, na última semana de orientação, o grupo foi desafiado pelo Docente a desenvolver um *dashboard* à semelhança do que outros grupos já estavam produzindo. Apesar de nenhum dos elementos do grupo ter tido contacto prévio com o Power BI, foi feito um esforço final nesse sentido, tendo resultado num *dashboard*⁶ interativo com o qual o grupo está satisfeito. Ainda que a sua utilidade prática possa ser limitada face às ferramentas já existentes na Câmara Municipal de Lisboa, constituiu uma oportunidade de aprendizagem relevante e um exercício de síntese visual de alguns dos resultados do estudo.

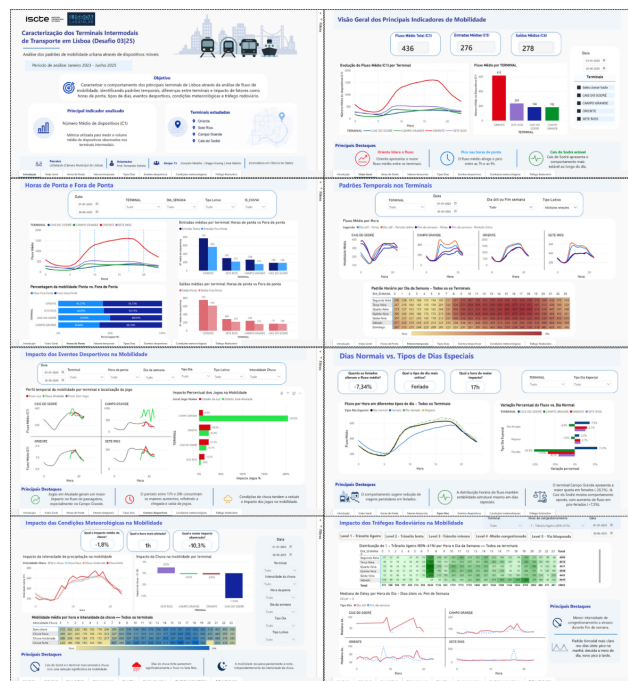


Figura 63: Dashboard interativo desenvolvido em Power BI para comunicação de alguns dos resultados do estudo.

⁶<https://drive.google.com/drive/folders/1-4bP-tjEw22CGFuvk9yek4hgvk8Gxe1U?usp=sharing>

Bibliografia

- Câmara Municipal de Lisboa. (2019). *Lisboa inteligente*. Lisboa Aberta. <https://lisboaaberta.cm-lisboa.pt/index.php/pt/lisboa-inteligente>
- FixtureDownload. (s.d.). *Fixture Download: Download football fixtures as CSV or iCal*. <https://fixturedownload.com>
- Instituto da Mobilidade e dos Transportes Terrestres. (2011). *Guião orientador: Acessibilidades, mobilidade e transportes nos planos municipais de ordenamento do território*. IMTT.
- Metropolitano de Lisboa. (2024, 30 de novembro). *Metropolitano de Lisboa atinge número recorde de transporte de passageiros*. <https://www.metrolisboa.pt/institucional/2024/11/30/metropolitano-de-lisboa-atinge-numero-recorde-de-transporte-de-passageiros/>
- MobilityData. (s.d.). *GTFS: General Transit Feed Specification*. <https://gtfs.org>
- NEC. (2019). *Intelligent Management Platform makes the city of Lisbon smarter*. <https://www.nec.com/en/global/onlinetv/en/lisbon.html>
- Overture Maps Foundation. (s.d.). *Overture Maps Foundation*. <https://overturemaps.org>
- Transitland. (s.d.). *Transitland: A community-edited data service aggregating transit networks*. <https://www.transit.land>
- Varela, T. J. A. (2016). *Interfaces de Transporte na AML e Novas Centralidades Metropolitanas* [Dissertação de mestrado, IGOT - Universidade de Lisboa]. Repositório Universidade de Lisboa. <http://hdl.handle.net/10451/26063>
- Vitorino, S. D. R. (2018). *Interfaces de transportes: caso prático em Alenquer. Interface de transporte em Alenquer* [Dissertação de mestrado, Iscte - Instituto Universitário de Lisboa]. Repositório do Iscte. <http://hdl.handle.net/10071/17688>
- World Data League. (s.d.). *Determining the main mobility flows in Lisbon based on mobile device data*. <https://www.worlddataleague.com/post/determining-the-main-mobility-flows-in-lisbon-based-on-mobile-device-data>
- Lemonde, C., Arsenio, E. & Henriques, R. Integrative analysis of multimodal traffic data: addressing open challenges using big data analytics in the city of Lisbon. <https://doi.org/10.1186/s12544-021-00520-3>
- Prommaharaj, P., Phithakkitnukoon, S., Demissie, M. G., Kattan, L., & Ratti, C. (2020). Visualizing public transit system operation with GTFS data: A case study of Calgary, Canada. <https://doi.org/10.1016/j.heliyon.2020.e03729>
- Yue, Y., Zhuang, Y., Yeh, A. G. O., Xie, J. Y., Ma, C. L., & Li, Q. Q. (2017). Measurements of POI-based mixed use and their relationships with neighbourhood vibrancy. *International Journal of Geographical Information Science*. <https://doi.org/10.1080/13658816.2016.1220561>
- Kumakoshi, Y., Koizumi, H., & Yoshimura, Y. (2021). Diversity and density of urban functions in station areas. *Computers, Environment and Urban Systems*. <https://doi.org/10.1016/j.compenvurbsys.2021.101679>

Anexo I — Resultados da Inspeção de Ficheiros CSV

a) Metodologia de Inspeção

Para realizar a análise extensiva e comparativa da estrutura de colunas existentes entre os diferentes ficheiros CSV foi desenvolvido e executado um *bash script* denominado ***audit_csv.sh***.

O *script* percorre recursivamente toda a árvore de diretórios a partir da pasta raiz dos dados brutos, identifica todos os ficheiros com extensão .csv (independentemente da capitalização) e extrai o cabeçalho de cada um, listando o nome exato de cada coluna e a sua posição ordinal. São também apresentadas amostras do conteúdo de cada ficheiro através dos comandos *head* (primeiras linhas) e *tail* (últimas linhas), o que facilitou a detecção de anomalias para além do cabeçalho — como a presença de linhas terminadas apenas em `\r` no final de alguns ficheiros Waze 2025 e o ficheiro de Outubro de 2024 (corresponde ao período com maior falta de dados do Waze) que terminava com um único atributo "4", sugerindo que houve algum erro no momento da extração dos dados.

Para além da listagem de colunas, o script implementa um mecanismo de detecção de anomalias que distingue três casos:

- CSV normal sem aspas: header lido diretamente (ex: `Grid_ID,Datetime,C1,...etc`).
- CSV QUOTE_ALL válido: todos os campos envolvidos em aspas duplas, formato RFC 4180 válido (ex: ficheiros IPMA 2023/2024 e Waze 2025).
- Formato anómalo: linha inteira encapsulada numa aspa externa adicional, com os campos internos duplamente escapados (ex: `"entity_ts,entity_id,...etc"`). Detectado via expressão regular Python embutida no *script*.

Esta inspeção foi implementada porque cedo detetámos este problema num dos ficheiros do conjunto de dados IPMA.

O *output* do programa é redirecionado para um ficheiro que é guardado com o nome ***relatorio_audit_csvs.txt*** na pasta raiz dos dados brutos, com *output* codificado em cores *ascii* para facilitar a leitura no terminal (para visualizar esse relatório recomendamos usar os comandos *cat* ou *bat* em ambientes *Unix*).

b) Resultados Globais

Métrica	Valor
Total de ficheiros CSV encontrados	157
Ficheiros com formato normal ou válido	156
Ficheiros com formato anómalo	1
Fontes de dados inspecionadas	4 (Vodafone Grelha, Vodafone Quadrículas, Waze Jams, IPMA)

c) Schemas Confirmados por Fonte

Vodafone Grelha — Evolução de Schema (4 períodos)

Schema	Período	N.º Cols	Colunas (nome exacto)
VOD-A	Jan–Dez 2023	10	Grid_ID, Datetime, C1, C3, C5, C6, C9, E7, E8, E9
VOD-B	Jan–Ago 2024	23	Grid_ID, Datetime, C1–C11, D1, E1–E10
VOD-C	Set 2024	8	grid_id, date, C1, C2, C3, C4, C5, C6 [capitalização mista]
VOD-D	Out 2024–2025	9	grid_id, date, c1, c2, c3, c4, c5, c6, year [tudo minúsculas]

Observações:

- O ficheiro VOD-C de Agosto 2024 (*PgilVodafoneA_202408_1_3743.csv*) é redundante — Agosto 2024 tem também os ficheiros VOD-B segmentados habituais que cobrem todos os Grid_IDs. Para Agosto, usar os ficheiros VOD-B.
- Setembro 2024 é o único mês sem ficheiros VOD-B: apenas existe *PgilVodafoneA_202409_1_3743.csv* (VOD-C, 8 colunas, porém capitalização mista: grid_id e date em minúsculas, C1–C6 em maiúsculas). Não há alternativa para Setembro 2024 — esta lacuna de cobertura deverá ser considerada na fase de Data Preparation.

Waze Jams

Schema consistente em todos os ficheiros inspeccionados (2023, 2024, 2025):

Atributo	Valor
N.º de colunas	8
Colunas	delay, entity_id, entity_ts, length, level, position, speed, street
Formato header	CSV QUOTE_ALL válido nos ficheiros de 2025; sem aspas nos ficheiros de 2023/2024

IPMA — Dados Meteorológicos

Dois schemas distintos, diferindo apenas na posição da coluna entity_ts:

Schema	Período	N.º Cols	Ordem das colunas (nome exacto)
IPMA-A	2023 SEM1	11	entity_id, estacion, humidade, iddireccvento, intensidadeventokm, precacumulada, pressao, radiacao, temperatura, fecha, entity_ts [entity_ts em último]
IPMA-B	2023 SEM2, 2024, 2025 (corrigido)	11	entity_ts, entity_id, estacion, humidade, iddireccvento, intensidadeventokm, precacumulada, pressao, radiacao, temperatura, fecha [entity_ts em primeiro]

Todos os ficheiros IPMA utilizam o formato CSV QUOTE_ALL válido (excepto o ficheiro original de 2025, descrito na secção seguinte).

d) Ficheiros com Formato Anómalo

A inspeção identificou 1 ficheiro com formato CSV anómalo:

Ficheiro	Descrição
IPMA/IPMA_2025/PGIL_IPMA_METEO_OBS_1Sem2025.csv	Ficheiro original. Cada linha está envolvida numa aspa dupla adicional externa, com os campos internos escapados como ". Formato não standard, incompatível com <i>parsers</i> CSV convencionais.

Este ficheiro CSV original estava mal formatado: cada linha estava envolvida em aspas externas desnecessárias, e as aspas internas dos campos estavam duplicadas (em vez de ").

Primeiras linhas tal como aparece no ficheiro original:

```
"entity_ts","entity_id","estacion","humidade","iddireccvento", ...  
"2025-01-01T00:54:30.166Z","ipma.estacionesMetereologicas.1200535","1200535", ...  
"2025-01-01T00:54:30.634Z","ipma.estacionesMetereologicas.1200579","1200579", ...
```

O problema foi resolvido com o seguinte comando *sed*:

```
sed 's/^"//;s/"\r\{0,1\}$//;s/"\r"/g' \  
IPMA_2025/PGIL_IPMA_METEO_OBS_1Sem2025.csv > \  
IPMA_2025/PGIL_IPMA_METEO_OBS_1Sem2025__corrigido.csv
```

O comando aplica três substituições encadeadas:

- (1) remove a aspa extra no início de cada linha;
- (2) remove a aspa extra no fim, com tolerância para terminações Windows (`\r\n`);
- (3) substitui todos os pares de aspas por uma aspa simples `"`, desfazendo o escape inválido.

O ficheiro corrigido resultante apresenta o schema IPMA-B normal com 11 colunas e `entity_ts` em primeiro lugar.

e) Anomalia de Linhas Vazias em Ficheiros Waze (Terminações CRLF)

O diagnóstico e a resolução seguiram os seguintes passos em ambos os casos:

Sintoma: O *tail* mostrava linhas sem conteúdo visível no terminal.

Causa raiz: Terminações de linha no formato Windows (CRLF, `\r\n`). As linhas “vazias” no final eram compostas apenas pelo carácter `\r`, tornando-as invisíveis no terminal mas presentes no ficheiro.

Solução aplicada: Edição in-place com *sed* para remover todas as linhas compostas exclusivamente por `\r`:

```
sed -i '/^\r$/d' waze_2025_01.csv
```

```
sed -i '/^\r$/d' waze_05_2024.csv
```

Após a aplicação do comando em cada ficheiro, ambos ficaram limpos das linhas inválidas/inúteis, sem necessidade de criar cópias. Não foram identificados outros ficheiros Waze com o mesmo problema — os dois casos aqui descritos são os únicos conhecidos.

Anexo II — Web Scraping aos Dados da Rede Expressos

a) Contexto e Motivação

A Rede Expressos é o maior operador de autocarros de longa distância em Portugal, servindo os terminais intermodais de Sete Rios e Oriente. Ao contrário de todos os outros operadores incluídos nesta análise (Metro, CP, Carris, Carris Metropolitana, TransTejo, Fertagus e FlixBus), a Rede Expressos não disponibiliza um *feed* GTFS público.

Esta ausência impossibilitou a integração directa dos seus dados no *pipeline* de processamento baseado em GTFS. Para não excluir um operador com peso significativo nos dois terminais, foi necessário recorrer a uma abordagem alternativa: a extração automatizada de horários directamente do *website* oficial da Rede Expressos.

O presente anexo documenta o processo técnico de descoberta e implementação do *scraper*, desde a identificação do *endpoint* de API interno até à estrutura final dos dados recolhidos.

b) Descoberta da API Interna

Inspecção do tráfego de rede via Chrome DevTools

O *website* da Rede Expressos (rede-expressos.pt) é uma *Single Page Application* (SPA) que comunica com uma API REST interna para obter os horários. A identificação desta API foi feita através da inspecção do tráfego de rede no Chrome DevTools (painel *Network*), acompanhando os pedidos HTTP gerados quando se efectua uma pesquisa de horários no formulário do *site*.

O procedimento de inspecção foi o seguinte:

- Abrir o Chrome DevTools e navegar para o separador *Network*;
- Activar o filtro “XHR / Fetch” para isolar pedidos de API;
- Preencher o formulário de pesquisa de horários com uma origem e um destino;
- Observar os pedidos HTTP gerados após clicar em “Pesquisar”.




Figura 64: Chrome DevTools — separador *Network* com filtro *XHR/Fetch* activo, mostrando o pedido *OneWayForSelectedDate*.

Identificação do *endpoint*

A inspecção revelou que a pesquisa de horários gera um único pedido HTTP POST para o seguinte *endpoint*:

```
POST https://webapi.rede-expressos.pt/api/App/OneWayForSelectedDate
```

Este *endpoint* está alojado num subdomínio separado (`webapi.rede-expressos.pt`), distinto do *site* principal, e aceita pedidos JSON com os parâmetros de pesquisa. A resposta é um objecto JSON com os horários disponíveis para a combinação origem-destino-data solicitada.

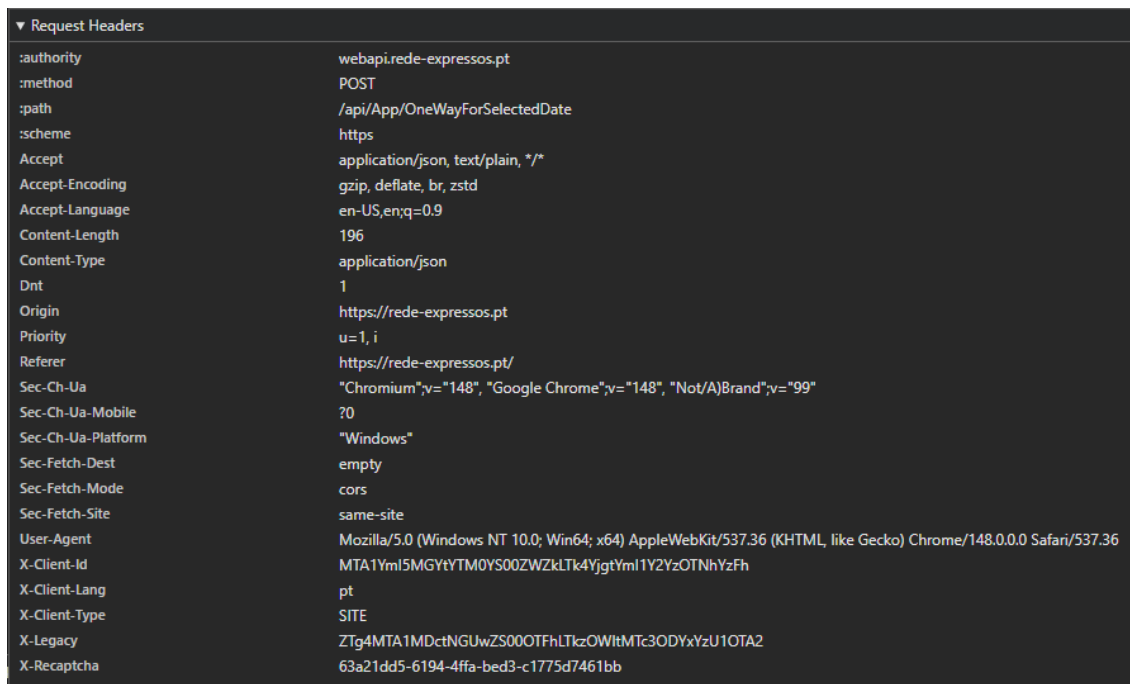


Figura 65: Detalhe dos Headers do pedido no DevTools.

Estrutura do *payload* (corpo do pedido)

O corpo do pedido POST é um objecto JSON com os parâmetros de pesquisa, nomeadamente os identificadores de origem (`from`) e destino (`to`), a data, e o número de passageiros.




Figura 66: DevTools — separador Payload mostrando o corpo JSON do pedido POST.

Os campos `from` e `to` correspondem a identificadores numéricos internos da Rede Expressos para cada destino/terminal. Estes códigos foram mapeados através da inspecção dos *dropdowns* do formulário (atributos HTML das opções) e documentados no ficheiro `Códigos Cidades.md`. Os terminais de Lisboa Sete Rios e Lisboa Oriente têm os IDs 1 e 3, respectivamente.

c) Desafios Técnicos e Soluções Adoptadas

Protecção Cloudflare

O *site* `rede-expressos.pt` utiliza Cloudflare como serviço de protecção contra *bots*. Pedidos feitos com um *browser* automatizado convencional (Selenium, Playwright em modo *headless*) são frequentemente bloqueados pelo “Cloudflare Challenge” antes de chegarem sequer ao formulário de pesquisa.

Para contornar esta protecção, foi utilizada a biblioteca *nodriver*⁷ para Python, que controla uma instância real do Chrome em modo visível (`headless=False`) através do protocolo CDP (*Chrome DevTools Protocol*). Esta abordagem é significativamente mais difícil de detectar como automatizada do que os *browsers* controlados pelos *drivers* convencionais, uma vez que não injeta o *script webdriver.js* que o Cloudflare detecta.




Figura 67: Verificação de segurança anti-bots da Cloudflare.

⁷<https://github.com/ultrafunkamsterdam/nodriver>

Token reCAPTCHA de curta duração

O token **X-Recaptcha** é gerado pelo Google reCAPTCHA v3 aquando da submissão do formulário de pesquisa e tem uma validade de aproximadamente dois minutos. Isto significa que não é possível obter o token uma única vez e reutilizá-lo para todos os pedidos — é necessário regenerá-lo periodicamente. A única forma de obter um token válido é executar a pesquisa no *browser* real, uma vez que o reCAPTCHA v3 avalia o comportamento do utilizador.

A solução implementada consiste na interceptação dos cabeçalhos de autenticação directamente no tráfego de rede do *browser*, via CDP, aquando da submissão de uma pesquisa de teste. O *script* preenche automaticamente o formulário (origem: Lisboa Sete Rios, destino: Porto Campenã) e captura os cabeçalhos do pedido resultante, que são depois reutilizados para os pedidos subsequentes via `fetch()` dentro do contexto do mesmo *browser*.

Execução dos pedidos via `fetch()` no contexto do *browser*

Uma vez que os pedidos directos com o `requests` do Python são bloqueados (ausência de sessão Cloudflare e token reCAPTCHA válido), todos os pedidos à API são efectuados através do método `fetch()` injectado via CDP no contexto da página aberta no *browser* Chrome. Desta forma, os pedidos partem com a sessão Cloudflare e os *cookies* correctos, e o servidor trata-os como pedidos legítimos do *site*.

O mecanismo é o seguinte:

- O *script* Python constrói o *payload* JSON e o dicionário de cabeçalhos com os tokens capturados;
- O *script* serializa este pedido como uma *string* JavaScript com `fetch()` e envia-o via CDP `Runtime.evaluate()`;
- O resultado (status HTTP + corpo JSON) é devolvido ao Python como *string* e depois desserializado.


```

420 # — Pedido à API (via fetch dentro do browser) —————
421
422 ✓ async def fetch_routes(tab, tokens, origem_id, destino_id, data):
423     payload = {
424         "from": origem_id,
425         "to": destino_id,
426         "date": data,
427         "campaign": "",
428         "isCampaignFirstSearch": False,
429         "returnNextMinPrice": False,
430         "passengers": [{"id": "1", "fareTypeId": "1", "fareTypeLabel": "Adulto (30 a 64)"}]
431     }
432
433     # Embebe os valores diretamente no JS (nodriver não suporta argumentos como o Playwright)
434     script = f"""
435     (async () => {{
436         try {{
437             const res = await fetch("https://webapi.rede-expressos.pt/api/App/OneWayForSelectedDate", {{
438                 method: "POST",
439                 headers: {{
440                     "Content-Type": "application/json",
441                     "Accept": "application/json, text/plain, */*",
442                     "Origin": "https://rede-expressos.pt",
443                     "Referer": "https://rede-expressos.pt/",
444                     "X-Client-Id": {json.dumps(tokens.get("X-Client-Id", ""))},
445                     "X-Client-Lang": {json.dumps(tokens.get("X-Client-Lang", "pt"))},
446                     "X-Client-Type": {json.dumps(tokens.get("X-Client-Type", "SITE"))},
447                     "X-Legacy": {json.dumps(tokens.get("X-Legacy", ""))},
448                     "X-Recaptcha": {json.dumps(tokens.get("X-Recaptcha", ""))},
449                 }},
450                 body: JSON.stringify({json.dumps(payload)})
451             });
452             const text = await res.text();
453             return JSON.stringify({{ status: res.status, body: text }});
454         }} catch(e) {{
455             return JSON.stringify({{ status: 0, body: e.toString() }});
456         }}
457     }})()
458     """
459
460     # tab.evaluate() não aguarda Promises - usar CDP Runtime.evaluate com await_promise=True
461     result = await tab.send(cdp.runtime.evaluate(
462         expression=script,
463         await_promise=True,
464         return_by_value=True,
465     ))
466     # tab.send_return_value(PromiseObject, FunctionResult)

```

Figura 68: Mecanismo de injeção do `fetch()` via CDP no contexto do browser.

Rate limiting (HTTP 429)

A API aplica um limite de pedidos por unidade de tempo. Quando o limite é excedido, o servidor responde com HTTP 429 (*Too Many Requests*). O *script* implementa uma estratégia de *backoff* exponencial: em caso de 429, aguarda 10 segundos na primeira tentativa, 20 na segunda, 30 na terceira, etc., até um máximo de 5 tentativas. Se todas falharem, o pedido é registado como sem resultado e o *script* continua.

Para minimizar a ocorrência de 429, foi configurado um *delay* base de 2 segundos entre cada pedido (parâmetro `DELAY_BASE`). Em situações de elevada carga, este valor pode ser aumentado para 3 ou mais segundos.

d) Estratégia e Volume de Recolha

Para agilizar a recolha, o *script* foi executado em paralelo em dois computadores, cada um a tratar um terminal de origem diferente, com o parâmetro `--origem`:

```

# Computador 1 --- Sete Rios
python scrap_rede_expressos.py --origem "Lisboa (Sete Rios)"

# Computador 2 --- Oriente
python scrap_rede_expressos.py --origem "Lisboa (Oriente)"

```

Recolha de dias específicos (Feriado)

Para o regime de Feriado, foi efectuada uma recolha dedicada para o dia 1 de maio de 2026 (Dia do Trabalhador), utilizando o parâmetro `--data`:

```
python scrap_rede_expressos.py --data "2026-05-01"
```

O modo `--data` preserva os dados dos restantes dias já recolhidos no ficheiro JSON e substitui ou adiciona apenas as entradas da data especificada, permitindo re-executar sem criar duplicados.

Sistema de *checkpoint* e retoma automática

O *script* implementa um sistema de *checkpoint* automático: a cada 50 pedidos, o progresso é guardado num ficheiro JSON de *checkpoint* (ex: `Lisboa_Sete_Rios_checkpoint.json`). Se o *script* for interrompido (fecho accidental, erro de rede, etc.), ao ser reiniciado retoma automaticamente a partir do último *checkpoint* sem necessidade de intervenção manual. O ficheiro de *checkpoint* é apagado no final de uma execução bem-sucedida.

É possível também especificar manualmente o ponto de retoma com o parâmetro `--start_at`:

```
python scrap_rede_expressos.py --origem "Lisboa (Sete Rios)" --start_at 450
```

Renovação automática de tokens

O *script* monitoriza as respostas da API e detecta a expiração dos tokens via HTTP 401 (*Unauthorized*). Quando isso acontece, executa automaticamente o processo de renovação de tokens (`get_fresh_tokens`): preenche o formulário de pesquisa no *browser* e captura os novos cabeçalhos, sem interrompimento da recolha.

e) Estrutura dos Dados Recolhidos

Formato e organização dos ficheiros

Os dados recolhidos são guardados em dois ficheiros JSON, um por terminal de origem:

- `Lisboa_Sete_Rios_rotas_expressos.json`
- `Lisboa_Oriente_rotas_expressos.json`

Cada ficheiro contém uma lista de objectos JSON, um por combinação origem-destino-data que retornou resultados.

Estrutura de cada entrada

Cada objecto na lista tem a seguinte estrutura de topo:

```
{
  "origem": "Lisboa (Sete Rios)",
  "origem_id": "1",
  "destino": "A do Pinto",
  "destino_id": "850",
  "data": "2026-04-18",
  "resposta": { ... }
}
```

O campo `resposta` contém directamente o objecto devolvido pela API, com os horários em `outgoingSchedules`, um por viagem disponível para essa combinação.

Campos-chave e a sua interpretação

Campo	Tipo	Descrição
<code>scheduleId</code>	string	Identificador único de cada viagem concretizada (serviço × destino específico). Equivalente ao <code>trip_id</code> no GTFS.
<code>departureTripId</code>	string	Identificador do serviço recorrente (hora e percurso fixos). Equivalente ao <code>route_id</code> no GTFS. O mesmo <code>departureTripId</code> pode aparecer em múltiplas <i>queries</i> de destino.
<code>departureTime</code>	string	Hora de partida no formato "HH:MM".
<code>arrivalTime</code>	string	Hora de chegada estimada.
<code>travelTime</code>	string	Duração da viagem (formato "XXh YYm").
<code>distance</code>	inteiro	Distância em quilómetros.
<code>departureCarrier</code>	objecto	Operador da viagem (nome e logótipo).

Desduplicação e contagem de rotas

Um aspecto crítico da estrutura dos dados é que o mesmo serviço (identificado pelo `departureTripId`) aparece repetido em múltiplas entradas do JSON — uma por cada destino consultado na rota. Por exemplo, um autocarro Lisboa–Porto que também serve Coimbra aparece nas entradas dos destinos “Porto (Campenhã)” e “Coimbra”, com o mesmo `departureTripId` mas `scheduleIds` distintos.

A metodologia de contagem adoptada no processamento (script `00_preparar_dados_expressos.py`) usa:

- `N_Rotas = departureTripId.nunique()` — número de serviços recorrentes distintos (equivalente a rotas), com desduplicação correcta;
- `N_Trips = scheduleId.nunique()` — número de concretizações únicas de serviço, usado para frequência horária.

f) Dependências e Requisitos de Execução

Biblioteca	Versão	Função
<code>nodriver</code>	≥ 0.35	Controlo do Chrome via CDP sem detecção de automação
<code>asyncio</code>	<code>stdlib</code>	Execução assíncrona dos pedidos
<code>json</code>	<code>stdlib</code>	Serialização/desserialização dos dados
<code>argparse</code>	<code>stdlib</code>	<i>Parsing</i> dos argumentos da linha de comandos
<code>datetime</code>	<code>stdlib</code>	Geração das datas dos próximos 7 dias

A instalação da dependência externa é feita via:

```
pip install nodriver
```

É necessário ter o Google Chrome instalado no sistema. O *script* abre o Chrome em modo visível (`headless=False`) — a janela do *browser* não deve ser fechada durante a execução.

g) Limitações e Considerações Metodológicas

- A API não é pública nem documentada, pelo que a sua estrutura pode mudar sem aviso. Alterações ao *site* podem tornar o *script* inoperacional.
- O *delay* de 2 segundos entre pedidos torna a recolha completa demorada — aproximadamente 1h30 por terminal, em condições normais.

- Os dados de feriado (1 de maio de 2026) foram recolhidos numa data diferente da usada para os restantes operadores GTFS (10 de junho de 2026 — Dia de Portugal), o que introduz uma pequena inconsistência temporal na comparação de regimes de feriado.
- A extração de dados da Rede Expressos foi realizada através de engenharia reversa da API interna do *website*, constituindo uma prova de conceito exploratória. Esta abordagem não é oficialmente documentada nem suportada pela operadora, pelo que os resultados devem ser interpretados com as devidas cautelas. Em particular, podem existir erros de interpretação ao nível dos identificadores utilizados. A correspondência entre os identificadores da API da Rede Expressos e os conceitos equivalentes nos dados GTFS é inferida e pode não ser totalmente precisa.
- Os dados recolhidos refletem o estado da oferta numa data de referência específica e podem não capturar a totalidade das ligações disponíveis.

Nota sobre uso ético: A recolha de dados foi efectuada exclusivamente para fins académicos e de investigação, com *delays* adequados entre pedidos para não sobrecarregar os servidores da Rede Expressos. Não foram recolhidos quaisquer dados pessoais. Os dados de horários são de natureza pública, acessíveis a qualquer utilizador do *site*.

Anexo III — Análise e Tratamento de Outliers da Variável C1

h) Análise e Tratamento de Outliers da Variável C1

A variável C1 corresponde à contagem de dispositivos móveis Vodafone únicos detetados numa quadrícula, sendo o principal *proxy* de procura utilizado neste projeto para estimar a presença e afluência de passageiros nos quatro terminais intermodais de Lisboa.

Antes de qualquer modelação ou análise estatística, foi necessário avaliar a qualidade desta variável, identificando registos com valores anómalos que possam distorcer médias e padrões horários. A análise foi desenvolvida em dois *notebooks* sequenciais:

- **Passo 1** — Identificação e remoção de *outliers* óbvios (valores com dimensão muito grande de forma isolada), seguida de listagem de todos os *fliers* residuais (pontos fora dos *whiskers* IQR) — `01_analise_outliers_c1_por_terminal.ipynb`;
- **Passo 2** — Para cada *flier*, cálculo de um *score* de legitimidade multi-critério e classificação em provável legítimo, duvidoso ou provável erro, de modo a avaliar o impacto de diferentes estratégias de remoção — `02_validacao_legitimidade_fliers_c1.ipynb`.




Figura 69: Análise visual da distribuição da variável C1. À esquerda, o histograma evidencia uma forte assimetria positiva (*right-skewed*), com o eixo das frequências em escala logarítmica. À direita, o gráfico Q-Q confirma o severo desvio dos dados face à distribuição normal teórica (linha vermelha).

Averiguação de Normalidade Através da análise gráfica (histograma e Q-Q *plot*) e testes estatísticos (Kolmogorov-Smirnov / Shapiro-Wilk), concluiu-se que a variável C1 não segue uma distribuição normal. Por esse motivo, foram descartados métodos baseados na média e no desvio padrão (*Z-score*), que são sensíveis à assimetria da distribuição. Em alternativa, aplicou-se o método categórico de Tukey adaptado ($1,5 \times \text{IQR}$).

Nota: Num caso perfeitamente normal, o limite de $1,5 \times \text{IQR}$ abrange cerca de 99,3% dos dados, identificando apenas os 0,7% mais extremos como *outliers*. Numa distribuição não-normal (geralmente muito assimétrica), são detetados mais casos — o que é expectável e aceitável —, cabendo depois uma análise de negócio para perceber se esses *fliers* são valores errados a limpar ou fenómenos reais importantes.

Estatísticas Descritivas

Terminal	Registos	Média	Mediana	P75	P99	Máximo
Cais do Sodré	1 978 501	276,22	150	385	1 422	73 617
Campo Grande	990 435	283,75	211	371	1 087	247 115

Terminal	Registos	Média	Mediana	P75	P99	Máximo
Oriente	965 663	989,60	868	1 403	3 005	87 978
Sete Rios	1 238 032	395,82	284	572	1 739	21 885

O terminal Oriente destaca-se pelos valores sistematicamente mais elevados (mediana 868 versus 150–284 nos restantes), reflexo da sua maior intermodalidade e do volume de passageiros que recebe. O Cais do Sodré apresenta a maior assimetria relativa, com mediana muito inferior à média.

Identificação de Outliers pelo Método IQR O método de Tukey ($k = 1,5$) foi aplicado a dois níveis: global (sobre o conjunto completo) e por terminal (separadamente para cada série). A abordagem por terminal é mais adequada porque evita que a escala do Oriente contamine os limiares dos outros terminais.

Terminal	Q1	Q3	IQR	Whisker Superior	Nº Outliers	% Outliers
Cais do Sodré	57	385	328	877	116 686	5,90%
Campo Grande	111	371	260	761	39 149	3,95%
Oriente	408	1 403	995	2 895	11 839	1,23%
Sete Rios	102	572	470	1 277	42 881	3,46%

Importa notar que não existem *outliers* negativos — todos os *outliers* identificados são valores superiores ao *whisker* superior.

Outliers Óbvios — Identificação e Remoção Uma inspeção visual dos *boxplots* revelou um pequeno conjunto de registos com valores de C1 de grandeza muito diferente dos restantes — várias ordens de magnitude acima do P99. Estes foram denominados *outliers* óbvios e removidos na primeira fase.




Figura 70: Boxplot de C1 por terminal com os outliers óbvios assinalados (elipses coloridas).

Foram identificados 13 *outliers* óbvios distribuídos por três terminais:

Terminal	Nº Removidos	Valor Máximo	Data	Dia
Cais do Sodré	1	73 617	2024-12-16 13:00	Segunda-feira
Campo Grande	11	247 115	2024-02-05 (tarde)	Segunda-feira
Oriente	1	87 978	2024-04-16 18:20	Terça-feira

O evento do Campo Grande em 2024-02-05 é o mais expressivo: 11 registos em dois GRID_IDs contíguos (2615 e 2616) durante a tarde, com pico de 247 115 dispositivos.

```

Total de outliers acima de 150.000: 11
  TERMINAL  GRID_ID      DATETIME      C1
CAMPO GRANDE  2615  2024-02-05  14:55:00  214069
CAMPO GRANDE  2615  2024-02-05  15:15:00  209737
CAMPO GRANDE  2615  2024-02-05  15:25:00  192494
CAMPO GRANDE  2616  2024-02-05  15:45:00  191243
CAMPO GRANDE  2616  2024-02-05  15:55:00  190675
CAMPO GRANDE  2616  2024-02-05  16:15:00  189807
CAMPO GRANDE  2616  2024-02-05  16:25:00  189238
CAMPO GRANDE  2615  2024-02-05  17:00:00  187257
CAMPO GRANDE  2615  2024-02-05  17:10:00  186305
CAMPO GRANDE  2615  2024-02-05  17:15:00  186056
CAMPO GRANDE  2615  2024-02-05  17:25:00  247115

```

Figura 71: Outliers óbvios do terminal Campo Grande em 2024-02-05.

Nota sobre o Campo Grande em 2024-02-05: Não foi possível identificar nenhum evento social associado a estes registos. Os 11 registos removidos têm valores até cerca de 228× superiores ao P99 do terminal (1 087), sugerindo uma anomalia de ingestão de dados e não um fenómeno real.

Fliers Remanescentes Após a remoção dos *outliers* óbvios, subsistem ainda 210 542 *fliers* — pontos acima do *whisker* superior. Estes podem não ser necessariamente erros: podem corresponder a eventos especiais, horas de ponta com grande concentração, entre outros.

Terminal	Whisker Superior	Nº Fliers	% dos Registos
Cais do Sodré	877	116 685	5,90%
Campo Grande	761	39 138	3,95%
Oriente	2 895	11 838	1,23%
Sete Rios	1 277	42 881	3,46%

Violin+Boxplots após Remoção dos Outliers Óbvios Após a remoção dos *outliers* óbvios, realizou-se uma visualização combinada *violin + boxplot* para cada terminal. Este gráfico permite observar simultaneamente a densidade da distribuição, os quartis e os valores extremos acima do *whisker*, em dois painéis: escala completa (para visualizar os *fliers* remanescentes) e escala ajustada ao *whisker* superior (para ver a estrutura IQR de cada terminal).




Figura 72: Violin+Boxplots de $C1$ por terminal após remoção dos outliers óbvios (escala completa, painel superior; escala ajustada, painel inferior).

A análise visual confirma que a distribuição de $C1$ é assimétrica e com cauda longa para valores elevados em todos os terminais. Com a escala ajustada, fica claro que Oriente tem a maior amplitude IQR (408–1 403) e os *whiskers* mais elevados (0–2 895), refletindo uma variabilidade de presença muito superior à dos restantes terminais.

Impacto dos Fliers no Fluxo Médio Horário Para avaliar se os *fliers* distorcem significativamente as análises, comparou-se o fluxo médio horário em quatro cenários cruzados: com/sem *outliers* óbvios $\times$ com/sem *fliers* IQR. A análise foi feita separadamente para dias úteis em período letivo e para fins de semana em período letivo.




Figura 73: Fluxo médio horário em dias úteis letivos (4 cenários sobrepostos).




Figura 74: Fluxo médio horário em fins de semana letivos (4 cenários sobrepostos).

A diferença entre reter ou remover *fliers* é substancial e particularmente visível em todos os terminais: quando preservados, todos eles revelam picos e permanências mais acentuadas.

Desde a fase de *Data Understanding* que existia consciência de ruído nos dados, proveniente da natureza das infraestruturas de sinalização de redes de dispositivos móveis (com possíveis falhas de registo e erros de medição), bem como pelo facto de pessoas sem relação direta com o uso dos terminais poderem atravessar as quadrículas em qualquer momento do dia e contribuir para inflacionar as contagens.

Picos grandes acima dos *whiskers* superiores podem igualmente documentar momentos críticos da cidade,

como grandes eventos urbanos (concertos, jogos de futebol), perturbações na rede de transportes (greves), ou dias de vento e/ou chuva intensa que conduzem as pessoas a procurar abrigo nos terminais. Embora atípicos, estes eventos ocorrem com alguma regularidade, pelo que se optou por não os remover de imediato, procedendo antes a uma análise de legitimidade.

i) Validação de Legitimidade dos Fliers C1

O segundo *notebook* implementa um sistema de *scoring* multi-critério para classificar cada um dos 210 542 *fliers* em três classes: *provável_legítimo*, *duvidoso* e *provável_erro*, com o objetivo de distinguir entre registos legítimos e erros de contagem.

Metodologia de Scoring O *score* de legitimidade (0–100) combina três dimensões independentes, com pesos ajustados à sua capacidade discriminante:

Critério	Peso	Descrição
Consistência temporal	40	O <i>flier</i> não está isolado no tempo — existem outros pontos anómalos nos intervalos de 5 min adjacentes.
Coerência com histórico horário	35	O desvio face à mediana horária do terminal é ≤ 3 IQR horários — distingue picos plausíveis de erros.
Consistência espacial	25	No mesmo instante, pelo menos outro GRID_ID do mesmo terminal também é <i>flier</i> — sugestivo de fenómeno real.

A classificação final baseia-se em dois limiares do *score*:

- **Score ≥ 60 :** provável legítimo — o *flier* apresenta características consistentes com um evento real;
- **Score < 40 :** provável erro — o *flier* é isolado, inconsistente com o histórico e sem contexto justificativo;
- **$40 \leq \text{Score} < 60$:** duvidoso — evidência insuficiente para uma classificação clara.

Resultados da Classificação A distribuição dos 210 542 *fliers* pelas três classes revela que a esmagadora maioria é considerada legítima pelo algoritmo:

Classe	N Fliers	% do Total de Fliers
Provável legítimo	179 158	85,1%
Duvidoso	19 170	9,1%
Provável erro	12 214	5,8%




Figura 75: Histograma do score de legitimidade por classe (empilhado).

Terminal	Duvidosos	Prováveis Erro	Prováveis Legítimos
Cais do Sodré	13 025 (11,16%)	4 269 (3,66%)	99 391 (85,18%)
Campo Grande	2 583 (6,60%)	3 847 (9,83%)	32 708 (83,57%)
Oriente	621 (5,25%)	1 057 (8,93%)	10 160 (85,82%)
Sete Rios	2 941 (6,86%)	3 041 (7,09%)	36 899 (86,05%)

Análise de Sensibilidade — Cenário A vs. Cenário B Para orientar a decisão de tratamento, compararam-se dois cenários de limpeza:

- **Cenário A** — remove apenas os prováveis erros (12 214 registos);
- **Cenário B** — remove prováveis erros e duvidosos (31 384 registos).




Figura 76: Fluxo médio horário por terminal em dias úteis letivos: Cenário A vs. Cenário B.




Figura 77: Fluxo médio horário por terminal em fins de semana letivos: Cenário A vs. Cenário B.

Os gráficos evidenciam que o Cenário B produz médias horárias sistematicamente mais baixas, mas sem excesso.